

Unidad Nro. 1: Introducción a la Minería de Datos y KDD

Sitio: [Instituto Superior Politécnico Córdoba](#)

Curso: Minería de Datos - TSCDIA - 2024

Libro: Unidad Nro. 1: Introducción a la Minería de Datos y KDD

Imprimido por: Gaston Dario Alberto DI CAMPLI PEREZ

Día: miércoles, 10 junio 2026, 12:34 PM

Tabla de contenidos

1. Introducción
2. Minería de Datos
3. Dato, Información y Conocimiento
4. Proceso de KDD (Knowledge Discovery in Databases)
5. Fuente de datos: DataWarehouse y Data Mart
6. Relación de KDD y la Minería de Datos
7. Cierre de la unidad
8. Actividad de autoevaluación

1. Introducción

En la actualidad, los datos se han convertido en uno de los activos más valiosos de las organizaciones. Cada interacción digital, transacción comercial, proceso productivo o actividad humana genera información que puede ser registrada, almacenada y analizada.

En este contexto, la **minería de datos** surge como una disciplina fundamental que permite explorar grandes volúmenes de datos con el fin de descubrir patrones, relaciones y conocimientos ocultos que resultan clave para la toma de decisiones.

Esta unidad tiene como objetivo introducir los conceptos esenciales de la minería de datos y su papel dentro del proceso de generación de conocimiento, abordando:

- ✓ Qué es la minería de datos y por qué es importante en distintos ámbitos
- ✓Cuál es la diferencia entre dato, información y conocimiento
- ✓Qué es el proceso KDD (Knowledge Discovery in Databases) y cuáles son sus etapas
- ✓Cuál es el rol de la minería de datos dentro del proceso de descubrimiento de conocimiento

Objetivos de aprendizaje

Al finalizar esta unidad, el estudiante será capaz de:

- ## 2. Minería de Datos



En este caso, los **datos de uso** se transforman en **información** (preferencias de consumo) y **luego en conocimiento** que permite tomar decisiones, como sugerir contenidos relevantes.

En este caso, los datos de uso se transforman en información (preferencias de consumo) y luego en conocimiento que permite tomar decisiones, como sugerir contenidos relevantes.

Este ejemplo muestra que los datos por sí solos no poseen un significado completo, sino que su valor surge a partir del procesamiento y análisis que permite interpretarlos.

Por este motivo, resulta fundamental distinguir entre los conceptos de **dato, información y conocimiento**, ya que representan distintos niveles en el proceso de generación de valor a partir de los datos.

3. Dato, Información y Conocimiento

La **minería de datos** se basa en el análisis de grandes volúmenes de datos con el objetivo de descubrir patrones y generar conocimiento útil.

En este contexto, resulta fundamental comprender la diferencia entre **dato, información y conocimiento**, ya que estos conceptos representan distintos niveles de procesamiento y permiten entender cómo se construye el valor a partir de los datos.

3.1 Dato

Un **dato** es un valor o registro sin procesar que representa un hecho aislado y que, por sí solo, no posee un significado completo. Puede tratarse de un número, una palabra, una fecha o una observación, sin contexto que permita interpretarlo adecuadamente.

Ejemplo:

25, "Aprobado", 08/03/2026

3.2 Información

La **información** surge cuando los datos son organizados, procesados y contextualizados, adquiriendo significado. En este nivel, los datos dejan de ser elementos aislados y comienzan a ofrecer una descripción comprensible de una situación.

Ejemplo:

"El promedio de notas del curso es 7"

En este caso, los datos individuales fueron procesados para generar un resultado que permite interpretar el desempeño general.

3.3 Conocimiento

El **conocimiento** se obtiene a partir de la interpretación de la información en un contexto determinado, permitiendo comprender una situación, establecer conclusiones y tomar decisiones.

Ejemplo:

"El rendimiento del curso es bueno, por lo que no es necesario reforzar contenidos"

En este nivel, la información es analizada y utilizada para generar una acción o decisión.

3.4 Relación entre dato, información y conocimiento

Para comprender el proceso mediante el cual los datos adquieren valor, es necesario considerar la relación existente entre dato, información y conocimiento como una **transformación progresiva**, en la que cada nivel implica un mayor grado de procesamiento, interpretación y significado.

👉 **Dato → Información → Conocimiento**

En este proceso, cada nivel implica un mayor grado de **procesamiento, interpretación y valor**.

Los datos constituyen el punto de partida, pero por sí solos carecen de significado. Al ser organizados y contextualizados, se transforman en información, que permite describir y comprender una situación. Finalmente, cuando esa información es interpretada y utilizada en un contexto determinado, se convierte en conocimiento.

Este proceso es fundamental en minería de datos, ya que el objetivo no es únicamente analizar datos, sino **generar conocimiento útil que permita tomar decisiones informadas**.

3.5 Fuentes de datos en minería de datos

Los **datos** que se analizan en **minería de datos** pueden provenir de diversas fuentes, dependiendo del contexto y del problema a resolver.

Entre las principales fuentes de datos se encuentran:

- ✓ **Bases de datos estructuradas:** como tablas de clientes, ventas o registros académicos, organizadas en filas y columnas, lo que facilita su almacenamiento, consulta y análisis.
- ✓ **Datos de plataformas digitales:** como historiales de navegación, visualización o interacción, que reflejan el comportamiento de los usuarios y permiten analizar preferencias y hábitos.
- ✓ **Datos generados por sistemas:** como logs o registros de uso de aplicaciones, que capturan eventos y actividades realizadas, siendo útiles para detectar patrones de uso o posibles anomalías.
- ✓ **Datos no estructurados:** como textos, imágenes, audios o videos, que no siguen una estructura predefinida y requieren técnicas específicas para su procesamiento y análisis.

Estas fuentes constituyen el punto de partida para el proceso de análisis, ya que a partir de estos datos se construyen la información y el conocimiento.

Es importante destacar que la calidad, variedad y volumen de los datos influyen directamente en los resultados obtenidos, por lo que su correcta selección y preparación resultan fundamentales en el proceso de minería de datos.

En este sentido, la diversidad de fuentes permite obtener una visión más completa del fenómeno analizado, enriqueciendo el proceso de descubrimiento de conocimiento.

4. Proceso de KDD (Knowledge Discovery in Databases)

La **minería de datos** permite analizar grandes volúmenes de datos para descubrir patrones y generar conocimiento. Sin embargo, este análisis no ocurre de manera aislada, sino que forma parte de un proceso más amplio.

En este contexto, el pasaje de *dato* → *información* → *conocimiento* se concreta a través del **proceso denominado KDD** (Knowledge Discovery in Databases).

4.1 Proceso KDD (Knowledge Discovery in Databases)

El **proceso KDD** comprende un conjunto de etapas interrelacionadas que permiten **transformar grandes volúmenes de datos en conocimiento útil**, a partir de su selección, preparación, análisis e interpretación.

Este proceso no se limita únicamente al análisis de los datos, sino que incluye actividades fundamentales como la **identificación de datos relevantes, su limpieza y transformación, la aplicación de técnicas analíticas y la evaluación de los resultados en función del contexto del problema**.

En este sentido, el KDD se concibe como un proceso **integral e iterativo**, en el que los resultados obtenidos pueden requerir volver a etapas anteriores para mejorar la calidad del análisis. Esto implica que no se trata de una secuencia lineal, sino de un proceso dinámico orientado a la generación de conocimiento significativo.

Asimismo, es importante considerar que el proceso KDD se encuentra **orientado a objetivos concretos**, ya sea comprender un fenómeno, identificar patrones o apoyar la toma de decisiones, lo que implica que cada etapa debe ser abordada en función del problema a resolver.

En este marco, la **minería de datos constituye una de las etapas del proceso KDD**, específicamente aquella en la que se aplican técnicas y algoritmos para descubrir patrones o modelos, siendo necesaria pero no suficiente para generar conocimiento por sí sola.

Por ello, el valor del proceso KDD reside en la **integración de todas sus etapas**, que en conjunto permiten convertir los datos en conocimiento aplicable en distintos contextos.

4.2 Etapas del proceso KDD

El proceso KDD se compone, de manera simplificada, de una serie de etapas que permiten **transformar los datos en conocimiento útil**, alineado a un objetivo de análisis o de negocio. Este proceso es **iterativo**, ya que los resultados pueden requerir volver a etapas anteriores para mejorar el análisis.

a. Selección:

En esta etapa se identifican y seleccionan los datos relevantes para el análisis, en función del problema a resolver. Implica decidir qué datos utilizar, de qué fuentes provienen y qué información resulta pertinente según los objetivos planteados.

b. Preprocesamiento:

Consiste en la limpieza y depuración de los datos. Se eliminan errores, valores faltantes, duplicados o inconsistencias. Esta etapa es clave, ya que **la calidad de los datos impacta directamente en la calidad de los resultados**.

c. Transformación:

Los datos se preparan para el análisis, adaptándolos a un formato adecuado. En esta etapa pueden realizarse tareas como:

- normalización
- reducción de datos

- generación de nuevas variables

d. Minería de datos:

Es la etapa en la que se aplican técnicas y algoritmos para descubrir patrones o modelos en los datos, con el objetivo de generar resultados que aporten valor al problema planteado.

Algunas tareas típicas son:

- clasificación (predecir categorías)
- agrupamiento (identificar grupos similares)
- reglas de asociación (relaciones entre variables)

e. Interpretación, evaluación y uso de resultados:

Los resultados obtenidos se analizan para determinar su validez y utilidad, interpretándolos en función del contexto del problema.

El objetivo es transformar los resultados en **conocimiento accionable**, que pueda ser utilizado para apoyar la toma de decisiones o mejorar procesos.

A continuación, se presenta una representación gráfica del proceso KDD, que permite visualizar de manera integrada las etapas descritas.



Figura: Representación del proceso KDD. Adaptado de Fayyad et al. (1996)

La representación gráfica permite comprender que el proceso KDD no se reduce a una secuencia de etapas aisladas, sino que constituye un **proceso integral, iterativo y orientado a objetivos**, en el que cada fase contribuye a la construcción de conocimiento.

En este sentido, el valor del proceso KDD no reside únicamente en la aplicación de algoritmos, sino en la **articulación de todas sus etapas**, desde la preparación de los datos hasta la interpretación de los resultados, lo que posibilita transformar los datos en conocimiento significativo y aplicable en contextos reales.

4.3 Ejemplo de aplicación del proceso KDD

Supongamos que un *supermercado* desea analizar las compras de sus clientes con el objetivo de comprender mejor sus hábitos de consumo y optimizar sus estrategias comerciales:

- **Selección:** se identifican y seleccionan los datos de ventas relevantes, como productos comprados, fechas y cantidades
- **Preprocesamiento:** se depuran los datos, eliminando registros incompletos o inconsistentes para asegurar su calidad
- **Transformación:** los datos se organizan y agrupan, por ejemplo, clasificando los productos por categorías o tipos
- **Minería de datos:** se aplican técnicas para identificar patrones, como la compra frecuente de ciertos productos en conjunto
- **Interpretación:** los resultados se analizan en función del contexto, permitiendo definir acciones como promociones, ubicación de productos o recomendaciones

El resultado final es la generación de **conocimiento útil**, que permite comprender el comportamiento de los clientes y mejorar la toma de decisiones comerciales.

Este ejemplo evidencia cómo, a través del proceso KDD, los datos pueden transformarse en información valiosa para la toma de decisiones.

5. Fuente de datos: DataWarehouse y Data Mart

Antes de analizar los datos, es necesario que estos se encuentren organizados y preparados en estructuras adecuadas para su explotación.

En el proceso de análisis de datos, la información no suele obtenerse directamente de los sistemas operacionales, sino que previamente es **organizada y consolidada** en estructuras diseñadas específicamente para su análisis.

En este contexto, aparecen dos conceptos clave: el **Data Warehouse** y el **DataMart**.

El **Data Warehouse** es un repositorio centralizado que integra datos provenientes de múltiples fuentes de la organización. Se caracteriza por almacenar grandes volúmenes de datos históricos, organizados de manera consistente, con el objetivo de facilitar el análisis global y la toma de decisiones a nivel organizacional.

Por su parte, un **DataMart** es una versión más acotada del Data Warehouse, orientada a un área específica o dominio particular, como ventas, marketing o rendimiento académico. Su principal ventaja es que permite trabajar con datos más focalizados, facilitando el análisis y reduciendo la complejidad.

En términos simples:

- **Data Warehouse** → visión global de la organización
- **DataMart** → visión específica de un área

5.1 Estructura de los datos

Tanto los Data Warehouse como los DataMart suelen organizar la información utilizando **modelos orientados al análisis**, distintos de los modelos transaccionales tradicionales.

Entre las estructuras más utilizadas se encuentran:

- **Esquema en estrella (Star Schema)**
Organiza los datos en una tabla central de hechos (por ejemplo, ventas o calificaciones) y varias tablas de dimensiones (como tiempo, estudiante, materia). Es simple y eficiente para consultas.
- **Esquema en copo de nieve (Snowflake Schema)**
Es una extensión del esquema en estrella, donde las dimensiones se encuentran normalizadas en varias tablas. Permite mayor organización, aunque con mayor complejidad.

Estas estructuras están diseñadas para facilitar la **consulta, exploración y análisis de los datos**, optimizando el rendimiento en tareas analíticas.

5.2 Proceso de preparación de los datos

En los entornos reales, los datos no se encuentran listos para su análisis desde el inicio. Por el contrario, suelen provenir de múltiples fuentes, con distintos formatos, estructuras y niveles de calidad.

Para poder utilizarlos de manera adecuada, es necesario aplicar un proceso que permita **integrarlos, organizarlos y prepararlos** antes de su análisis.

En este contexto, existe un proceso conocido como **ETL (Extract, Transform, Load)**, que tiene como objetivo reunir los datos desde diferentes fuentes, transformarlos para que sean consistentes y finalmente cargarlos en estructuras como Data Warehouse o DataMart.

Este proceso permite que los datos queden organizados y disponibles para su posterior exploración y análisis.

Sin embargo, es importante destacar que, aunque los datos estén integrados, aún pueden requerir tareas adicionales de preparación, las cuales serán abordadas en la siguiente unidad.

5.3 Ubicación en el proceso KDD

En el proceso KDD (Knowledge Discovery in Databases), el Data Warehouse y los DataMart forman parte de la etapa de **selección e integración de datos**, ya que constituyen la fuente desde la cual se obtienen los datos para su posterior preparación, exploración y análisis.

6. Relación de KDD y la Minería de Datos

En el contexto del análisis de datos, resulta fundamental distinguir entre la **minería de datos** y el proceso **KDD (Knowledge Discovery in Databases)**, ya que, si bien ambos se encuentran estrechamente relacionados, cumplen roles diferentes dentro del proceso de generación de conocimiento.

El proceso KDD constituye el **marco integral** que permite transformar datos en conocimiento útil, abarcando desde la selección y preparación de los datos hasta la interpretación de los resultados. Por su parte, la minería de datos se inserta dentro de este proceso como una etapa específica, orientada a la **identificación de patrones, relaciones o modelos** mediante la aplicación de técnicas y algoritmos.

Desde esta perspectiva, la minería de datos no puede entenderse de forma aislada, ya que su efectividad depende de la calidad de los datos utilizados, de las etapas previas de preparación y de la adecuada interpretación de los resultados en función del contexto del problema.

5.1 Relación entre KDD y Minería de Datos

La relación entre el proceso KDD y la minería de datos puede analizarse a partir de los siguientes aspectos:

- **Minería de datos como subconjunto del KDD:**
La minería de datos forma parte del proceso KDD y requiere de las etapas previas de selección, limpieza y transformación de los datos para garantizar la validez y confiabilidad de los resultados obtenidos.


- **Diferencia de enfoque:**

El KDD aborda el proceso completo de conversión de datos en conocimiento, integrando distintas etapas y actividades, mientras que la minería de datos se centra en la aplicación de técnicas específicas para el descubrimiento de patrones dentro de los datos.

- **Interdependencia entre etapas:**

La minería de datos aporta los modelos y patrones identificados, mientras que el KDD proporciona el contexto, la preparación de los datos y la interpretación necesaria para convertir dichos resultados en conocimiento significativo y aplicable.

La siguiente representación gráfica sintetiza la relación entre el proceso KDD y la minería de datos, destacando su integración dentro del proceso de generación de conocimiento.



En síntesis, la relación entre el proceso KDD y la minería de datos es **complementaria e inseparable**.

Mientras que el KDD proporciona el marco integral que permite transformar datos en conocimiento, la minería de datos se encarga de descubrir los patrones y relaciones que emergen de los datos dentro de ese proceso.

Comprender esta distinción resulta fundamental, ya que permite reconocer que la obtención de resultados significativos **no depende únicamente de la aplicación de técnicas**, sino de la correcta integración de todas las etapas que intervienen en el análisis de datos.

En este sentido, el valor del análisis de datos no reside exclusivamente en los algoritmos utilizados, sino en la capacidad de articular un proceso completo que permita transformar los datos en conocimiento útil y aplicable en distintos contextos.

7. Cierre de la unidad

A lo largo de esta unidad se abordaron los fundamentos de la **minería de datos** como una disciplina orientada a **transformar datos en conocimiento útil**, con el propósito de apoyar la comprensión de fenómenos y la toma de decisiones en distintos contextos.

En este marco, se partió de la idea de que los datos, por sí solos, no poseen un significado completo, sino que requieren ser **procesados, analizados e interpretados dentro de un contexto** para adquirir valor.

6.1 De los datos al conocimiento

En este recorrido se estableció la distinción entre tres niveles fundamentales en el análisis de datos:

- **Dato:** entendido como un valor aislado, sin contexto ni significado propio
- **Información:** resultado de la organización y procesamiento de los datos, que adquiere significado
- **Conocimiento:** producto de la interpretación de la información, que permite comprender una situación y orientar la acción

Este proceso de transformación progresiva constituye el **eje central de la minería de datos**, ya que permite convertir datos en elementos significativos para la toma de decisiones.

6.2 La minería de datos dentro del proceso KDD

Asimismo, se comprendió que la minería de datos no actúa de manera aislada, sino que se integra dentro del proceso **KDD (Knowledge Discovery in Databases)**, el cual estructura el pasaje de los datos al conocimiento a través de distintas etapas interrelacionadas.

Entre ellas se destacan:

- recolección y selección de datos
- limpieza y preparación
- análisis mediante técnicas de minería de datos
- interpretación de resultados

- toma de decisiones

En este sentido, la minería de datos se posiciona como una **etapa clave dentro del proceso KDD**, orientada al descubrimiento de patrones y relaciones significativas, pero cuya efectividad depende de la integración con las demás etapas del proceso.

6.3 El rol del analista de datos

En este proceso, el analista de datos cumple un rol fundamental, ya que no solo se encarga de aplicar técnicas, sino también de **interpretar los resultados en función del contexto y darles significado**.

Entre sus principales responsabilidades se encuentran:

- interpretar la información obtenida
- comunicar los resultados de manera clara y comprensible
- proponer acciones o decisiones basadas en evidencia

De este modo, el análisis de datos se constituye como un **soporte estratégico para la toma de decisiones informadas**.

6.4 Reflexión final

En conclusión, la minería de datos no se limita al uso de herramientas o algoritmos, sino que implica un **proceso integral de comprensión, análisis e interpretación de los datos**.

El verdadero valor no reside en los datos en sí mismos, sino en la **capacidad de transformarlos en conocimiento significativo** y en la posibilidad de utilizar ese conocimiento para fundamentar decisiones.

En este sentido, el proceso de análisis de datos puede entenderse como un recorrido que va:

- 👉 de los datos... a la información...
- 👉 de la información... al conocimiento...
- 👉 y del conocimiento... a la acción.

8. Actividad de autoevaluación

Objetivo de la autoevaluación

Verificar la comprensión de los conceptos fundamentales: dato, información, conocimiento, minería de datos y proceso KDD.

Respondé (brevemente)

a. ¿Qué es un dato? (Definilo en una sola frase)

👉 Indicá cuál de los siguientes es un dato:

- a) "El promedio del curso es 7"
- b) 8
- c) "Los estudiantes mejoraron su rendimiento"

b. ¿Cuál es la diferencia entre dato e información? (Explicalo brevemente)

c. ¿Qué es la minería de datos? (Elegí la opción correcta)

- 1) Guardar datos en una base de datos
- 2) Analizar datos para descubrir patrones
- 3) Crear gráficos
- 4) Eliminar datos incorrectos

d. El proceso KDD...

- a) Es lo mismo que minería de datos
- b) Es un proceso más amplio donde la minería es una etapa
- c) Solo incluye análisis de datos
- d) No tiene relación con los datos