

Unidad Nro. 2: Preparación de los datos

Sitio: [Instituto Superior Politécnico Córdoba](#)
Curso: Minería de Datos - TSCDIA - 2024
Libro: Unidad Nro. 2: Preparación de los datos

Imprimido por: Gaston Dario Alberto DI CAMPLI PEREZ
Día: miércoles, 10 junio 2026, 12:35 PM

Tabla de contenidos

- 2. Importancia en la calidad de los datos
- 3. Limpieza de datos
 - 3.1 Datos faltantes
 - 3.2 Datos atípicos
 - 3.3 Transformación de variables
- 4. Uso de gráficos para detectar problemas en los datos
- 5. Importancia de la preparación de datos en el descubrimiento de patrones
- 6. Cierre de la Unidad
- 7. Autoevaluación

En los entornos reales, los datos no provienen de una única fuente, sino que suelen ser **integrados y organizados previamente** mediante procesos que permiten unificarlos. Uno de estos procesos es conocido como **ETL (Extract, Transform, Load)**, que permite reunir datos desde distintas fuentes, transformarlos y almacenarlos en estructuras preparadas para su análisis.

A modo de ejemplo de un proceso ETL, supongamos que se dispone de dos archivos: uno con las notas de los estudiantes y otro con su asistencia. Antes de analizarlos, es necesario unificarlos en un mismo conjunto de datos. Este proceso de integración forma parte de lo que se **conoce como ETL**. Una vez integrados, los datos pueden ser analizados, aunque aún será necesario evaluar su calidad y prepararlos adecuadamente.

Sin embargo, aunque los datos estén integrados, esto no garantiza que sean correctos o adecuados para analizar. Por este motivo, resulta fundamental trabajar sobre la **calidad de los datos**, ya que constituye un aspecto central en cualquier proceso de análisis y determina directamente la validez y confiabilidad de los resultados obtenidos.

En el contexto de la minería de datos y del proceso KDD (Knowledge Discovery in Databases), las técnicas de análisis operan sobre los datos disponibles sin cuestionar su veracidad ni corregir sus posibles errores. Por lo tanto, los resultados generados reflejan, en gran medida, la calidad de la información de entrada.

En este sentido, resulta pertinente la expresión ampliamente utilizada en el ámbito del análisis de datos: **“Garbage In, Garbage Out” (basura entra, basura sale)**. Esta idea enfatiza que, independientemente de la complejidad o sofisticación de las técnicas empleadas, si los datos presentan inconsistencias, errores o incompletitud, las conclusiones obtenidas serán poco fiables o incluso incorrectas.

2.1 Relación entre calidad de datos y resultados

Desde una perspectiva conceptual, el proceso de análisis puede entenderse como una secuencia en la que los datos de entrada son transformados mediante distintos tipos de procesamiento (estadístico, visual o algorítmico) para obtener resultados que luego son interpretados con el objetivo de generar información y conocimiento útil.

Si los **datos iniciales son de baja calidad**, el **procesamiento no puede compensar esas deficiencias**, sino que tiende a reproducirlas o incluso amplificarlas. Por el contrario, cuando los datos son adecuados, el análisis tiene mayores probabilidades de generar conocimiento válido y útil.

Esta relación directa entre calidad de los datos y calidad de los resultados refuerza la necesidad de prestar especial atención a las etapas iniciales del proceso de análisis.

En este sentido, la siguiente figura ilustra de manera clara cómo la calidad de los datos condiciona directamente el proceso de análisis. Si los datos de entrada son incorrectos, incompletos o presentan inconsistencias, los resultados obtenidos reflejarán esas mismas limitaciones. Esto pone en evidencia que un análisis sólido no depende únicamente de las técnicas utilizadas, sino fundamentalmente de la calidad de los datos sobre los que se trabaja.

2.2 Dimensiones de la calidad de los datos

Un conjunto de datos se considera de calidad cuando cumple con ciertas propiedades fundamentales que garantizan su adecuación para el análisis.

En primer lugar, debe ser **completo**, es decir, **no presentar valores faltantes** que afecten la interpretación de los resultados. En segundo lugar, debe ser **correcto**, lo que implica que los valores registrados representen adecuadamente la realidad observada.

Asimismo, debe ser **consistente, evitando contradicciones** entre distintos datos o dentro de una misma variable. También es necesario que sea **relevante**, es decir, que los datos incluidos sean pertinentes en relación con el objetivo del análisis. Finalmente, los datos deben estar actualizados, de modo que reflejen una situación vigente y no obsoleta.

Estas dimensiones no actúan de manera aislada, sino que se encuentran interrelacionadas, por lo que la ausencia o debilidad en cualquiera de ellas puede comprometer significativamente el proceso analítico en su conjunto.

2.3 Ejemplo aplicado

A modo de ejemplo, consideremos un **dataset de estudiantes que presenta edades negativas, notas que superan el valor máximo permitido y campos vacíos en variables importantes**.

En estas condiciones, cualquier análisis posterior, como el cálculo de promedios, la generación de gráficos o la identificación de patrones producirá resultados distorsionados. En consecuencia, las conclusiones derivadas de dicho análisis no serán confiables ni útiles para la toma de decisiones.

2.4 Síntesis

En síntesis, la calidad de los datos no debe considerarse como una etapa secundaria o meramente técnica, sino como un requisito fundamental para el desarrollo de análisis válidos. Antes de aplicar cualquier técnica de minería de datos, es imprescindible comprender, evaluar y preparar adecuadamente los datos disponibles, ya que sobre ellos se construye todo el proceso de generación de conocimiento.

En este sentido, en los próximos apartados se abordarán las técnicas necesarias para mejorar la calidad de los datos, incluyendo su limpieza, transformación y preparación para el análisis.

La **limpieza de datos** es una etapa fundamental dentro del proceso de preparación, cuyo **objetivo es detectar, corregir o eliminar errores e inconsistencias** presentes en los datos, con el fin de mejorar su calidad y garantizar la confiabilidad del análisis posterior.

En muchos casos, los datos provienen de múltiples fuentes o han sido recolectados sin controles estrictos, lo que puede dar lugar a problemas como valores incorrectos, registros incompletos o formatos heterogéneos. La limpieza de datos permite abordar estas situaciones, asegurando que el conjunto de datos sea coherente, consistente y apto para su análisis.

Entre las tareas más comunes de este proceso se encuentran:

- **Eliminación de registros duplicados**, que pueden distorsionar los resultados del análisis
- **Corrección de errores tipográficos**, especialmente en variables categóricas (por ejemplo, nombres mal escritos o categorías inconsistentes)
- **Unificación de formatos**, como fechas, nombres o unidades de medida, que suelen presentarse de manera diversa dentro del mismo dataset
- **Validación de rangos de valores**, para detectar datos fuera de los límites esperados (por ejemplo, edades negativas o notas superiores al máximo permitido)

Estas acciones contribuyen a reducir el ruido en los datos y a mejorar la precisión y confiabilidad de los resultados obtenidos.

En síntesis, la limpieza de datos no solo implica corregir errores visibles, sino también garantizar la coherencia interna del dataset, constituyendo un paso clave para la generación de conocimiento confiable.

Los **datos faltantes** corresponden a valores que **no se encuentran registrados** en un conjunto de datos. Este tipo de problema es frecuente en procesos de recolección y almacenamiento de información, y puede afectar significativamente la calidad del análisis, ya que introduce incompletitud en el dataset y puede generar sesgos en los resultados.

La **presencia de datos faltantes puede tener diversas causas**, generalmente asociadas a dificultades en el proceso de obtención o registro de la información. Entre las razones más comunes se encuentran:

- ✓ **Errores en la carga de datos**, ya sea por omisiones humanas o fallas durante la digitación.
- ✓ **Información no disponible**, cuando ciertos datos no pudieron ser relevados en el momento de la recolección.
- ✓ **Fallas en los sistemas**, que pueden provocar la pérdida o no registro de determinados valores.

Comprender el origen de los datos faltantes resulta fundamental para decidir cómo tratarlos, ya que no todos los casos deben abordarse de la misma manera dentro del proceso de preparación de datos.

3.1.1 Tratamiento de datos faltantes

El **tratamiento de los datos faltantes** constituye una etapa clave dentro de la preparación de datos, ya que su manejo inadecuado puede introducir sesgos o afectar la validez de los resultados. La estrategia a aplicar no es única, sino que depende del contexto del problema, del volumen de datos faltantes y del tipo de variable involucrada.

En términos generales, las decisiones deben tomarse considerando el impacto que dichas ausencias pueden tener sobre el análisis y la interpretación de los resultados.

Entre **las estrategias más comunes para el tratamiento de datos faltantes** se encuentran:

- **Eliminación de registros**, cuando la cantidad de datos faltantes es reducida y su exclusión no afecta significativamente el tamaño ni la representatividad del dataset
- **Imputación de valores**, es decir, el reemplazo de los datos faltantes por valores estimados (esta estrategia varía según el tipo de dato)

Para **variables numéricas**, se pueden utilizar:

- **Promedio**, cuando los datos no presentan valores extremos significativos
- **Mediana**, cuando existen valores atípicos, ya que es más robusta frente a estos

Para **variables no numéricas (categóricas)**, se suele utilizar:

- **Valor más frecuente (moda)**, asignando la categoría que aparece con mayor frecuencia en el conjunto de datos
- **Mantenimiento de los datos faltantes**, en aquellos casos en los que la ausencia de información tiene un significado propio (por ejemplo, cuando la falta de respuesta es relevante para el análisis)

La elección de la estrategia adecuada requiere comprender tanto la naturaleza de los datos como el objetivo del análisis, ya que una decisión incorrecta puede alterar los patrones detectados y conducir a conclusiones erróneas.

3.1.2 Ejemplo aplicado de datos faltantes

Para comprender mejor el impacto y tratamiento de los datos faltantes, consideremos el siguiente ejemplo.

Supongamos un **dataset de estudiantes** que contiene las siguientes variables: **Nombre, Edad, Nota y Carrera**.

Nombre	Edad	Nota	Carrera
Ana	20	8	Sistemas
Juan		7	Sistemas
María	22		
Pedro	21	6	Industrial

En este dataset se observan distintos casos de **datos faltantes**:

- En el caso de Juan, falta el valor de la **Edad** (variable numérica).
- En el caso de María, falta la **Nota** (variable numérica) y la **Carrera** (variable categórica).

Estas ausencias pueden afectar el análisis. Por ejemplo, el cálculo del **promedio de edad** o del **promedio de notas** se verá condicionado por los valores faltantes, y el análisis por carrera será incompleto.

Frente a esta situación, pueden aplicarse distintas estrategias:

- Para la variable **Edad**, se podría reemplazar el valor faltante por el **promedio** o la **mediana** de las edades disponibles.
- Para la variable **Nota**, se podría aplicar una estrategia similar, considerando si existen o no valores atípicos.
- Para la variable **Carrera**, se podría reemplazar el valor faltante por la **categoría más frecuente** o bien mantenerlo como dato faltante si se considera relevante su ausencia.

Asimismo, si la cantidad de registros con datos faltantes fuera muy baja, también podría evaluarse la **eliminación de dichos registros**, siempre que esto no afecte la representatividad del conjunto de datos.

Este ejemplo permite observar que el tratamiento de los datos faltantes no es automático, sino que requiere un análisis cuidadoso del **tipo de variable**, del **contexto** y del **objetivo del estudio**.

Los **datos atípicos** (outliers) son valores que se **alejan significativamente del comportamiento general** del conjunto de datos. Estos valores pueden diferir notablemente del resto de las observaciones y, en consecuencia, pueden influir de manera considerable en los resultados del análisis.

La presencia de outliers es especialmente relevante en variables numéricas, ya que pueden afectar medidas estadísticas como el **promedio**, la **desviación** y la **dispersión**, generando interpretaciones distorsionadas.

Desde el punto de vista analítico, los datos atípicos no deben ser tratados automáticamente como errores. En algunos casos, pueden deberse a **errores de medición o carga de datos**, mientras que en otros pueden representar **situaciones reales y significativas** que aportan información valiosa.

Por lo tanto, la identificación de outliers requiere un análisis cuidadoso que permita distinguir entre valores incorrectos y valores válidos pero poco frecuentes.

3.2.1 Tratamiento de datos atípicos

El tratamiento de los datos atípicos depende del **contexto del problema**, del **tipo de variable** y del **objetivo del análisis**. No existe una única estrategia válida, sino que la decisión debe tomarse en función del impacto que estos valores tienen sobre los resultados.

Entre las acciones más comunes se encuentran:

- **Verificación del dato**, con el objetivo de determinar si el valor corresponde a un **error de carga o medición**.
- **Corrección o eliminación del valor**, en aquellos casos en los que se confirme que el dato es incorrecto.
- **Análisis del dato como caso especial**, cuando el valor es válido pero representa una situación poco frecuente que puede ser relevante para el estudio.

En este sentido, es importante destacar que eliminar un outlier sin un análisis previo puede implicar la pérdida de información valiosa.

3.2.2 Ejemplo aplicado de datos atípicos

Para ilustrar este concepto, consideremos el siguiente conjunto de datos correspondiente a las **notas de un grupo de estudiantes**:

6, 7, 8, 7, 6, 100

En este caso, el valor **100** se aleja significativamente del resto de las observaciones, que se encuentran en un rango cercano entre 6 y 8. Por lo tanto, este valor puede identificarse como un **dato atípico**.

Frente a esta situación, pueden plantearse distintas alternativas:

- Verificar si el valor **100** corresponde a un **error de carga** (por ejemplo, si debería haber sido 10).
- Corregir o eliminar el dato en caso de confirmarse el error.
- Analizarlo como un **caso especial**, si el valor es correcto y representa una situación excepcional dentro del conjunto de datos.

Este ejemplo permite comprender que los datos atípicos no deben ser tratados de manera automática, sino que requieren un análisis que considere tanto la **naturaleza de los datos** como el **objetivo del estudio**.

La **transformación de variables** es una etapa del proceso de preparación de datos que consiste en **modificar la escala, forma o representación de los datos** con el objetivo de facilitar su análisis y mejorar el desempeño de las técnicas aplicadas.

En muchos casos, los datos originales no se encuentran en condiciones adecuadas para ser analizados directamente, ya sea porque presentan **diferencias de escala, unidades incompatibles** o distribuciones que dificultan la interpretación. La transformación permite adaptar estos datos para hacerlos **comparables, consistentes y adecuados** para el análisis.

3.3.1 Tipos de transformaciones de variable

Existen distintas formas de transformar los datos, dependiendo del objetivo del análisis y del tipo de variables involucradas. Entre las más comunes se encuentran:

- **Escalado de datos**, que consiste en ajustar los valores a un rango específico (por ejemplo, entre 0 y 1).
- **Normalización**, que permite llevar los datos a una escala común, facilitando la comparación entre variables.
- **Cambio de unidades**, transformando los valores a una unidad homogénea (por ejemplo, de centímetros a metros).
- **Agrupamiento de valores**, que implica transformar variables continuas en categorías (por ejemplo, edades en rangos: joven, adulto, mayor).

Estas transformaciones permiten reducir diferencias artificiales entre variables y mejorar la calidad del análisis.

3.3.2 Importancia de la transformación de variable

Este proceso resulta especialmente importante en el contexto de la minería de datos, donde diversas técnicas requieren que las variables se encuentren en **rangos similares** o cumplan ciertas condiciones para producir resultados confiables.

La transformación de variables es fundamental porque muchas técnicas de análisis y algoritmos de minería de datos son sensibles a la **escala de los datos**. Cuando las variables presentan rangos muy distintos, aquellas con valores más grandes pueden tener una **influencia desproporcionada** en los resultados.

Por lo tanto, transformar los datos permite garantizar que todas las variables contribuyan de manera **equilibrada** al análisis, evitando sesgos y mejorando la interpretación de los resultados.

3.3.3 Ejemplo aplicado de la transformación de variables (Normalización)

Consideremos un dataset que contiene la variable Nota de un grupo de estudiantes:

Nota
4
6
8
10

En este caso, las notas se encuentran en una escala de **0 a 10**. Sin embargo, si se desea comparar esta variable con otra que está en una escala diferente (por ejemplo, de 0 a 100), resulta conveniente llevar ambas a un **mismo rango**.

Para ello, se puede aplicar una **normalización**, transformando los valores a un rango entre **0 y 1**.

El procedimiento consiste en tomar cada valor y dividirlo por el valor máximo (en este caso, 10):

- $4 \rightarrow 0.4$
- $6 \rightarrow 0.6$
- $8 \rightarrow 0.8$
- $10 \rightarrow 1.0$

De este modo, la variable queda expresada en una **escala común**, lo que facilita su comparación con otras variables y su uso en distintos métodos de análisis.

Este ejemplo permite comprender que la normalización no modifica la **relación entre los datos**, sino que ajusta su escala para hacerlos **comparables y más manejables** dentro del proceso de análisis.

3.3.4 Otro ejemplo aplicado de la transformación de variables

Consideremos un dataset que contiene la variable **Edad** de un grupo de personas:

Edad
18
25
40
70

Si el objetivo del análisis es segmentar a las personas en grupos, puede resultar más útil transformar esta variable numérica en una **variable categórica** mediante un proceso de agrupamiento.

Por ejemplo:

- 18–25 → **Joven**
- 26–59 → **Adulto**
- 60 o más → **Adulto mayor**

De esta manera, la variable original se transforma en categorías que facilitan la **interpretación** y el **análisis**, especialmente cuando se desea comparar comportamientos entre grupos.

Este ejemplo muestra que la transformación de variables no siempre implica cambiar la escala numérica, sino que también puede consistir en **reorganizar los datos para hacerlos más significativos** en función del objetivo del estudio.

En la etapa de **preparación de datos**, la **visualización puede utilizarse como una herramienta de apoyo para identificar posibles problemas en los datos**.

A través de gráficos simples es posible detectar valores atípicos, datos faltantes o inconsistencias que no siempre son evidentes al observar los datos en forma tabular.

A continuación, se presentan algunos de los gráficos más utilizados para detectar problemas en los datos.

En esta instancia, la visualización no se utiliza con fines de análisis, sino como un recurso para mejorar la calidad de los datos antes de su procesamiento.

4.1 Histograma

El histograma es un gráfico que **representa la distribución de los valores de una variable cuantitativa, agrupándolos en intervalos o rangos**.

Permite analizar cómo se distribuyen los datos, identificar concentraciones, dispersiones y posibles irregularidades en el conjunto. Es especialmente útil para variables numéricas como: notas, edades, ingresos, cantidades, etc.

¿Para qué sirve?


- Visualizar la forma de la distribución (uniforme, sesgada, concentrada)
- Detectar acumulaciones inusuales de datos
- Identificar posibles errores de carga

¿Qué anomalías puede mostrar?

- Valores fuera de rango (outliers)
- Distribuciones anómalas (por ejemplo, valores muy dispersos o concentraciones inesperadas)
- Posibles errores de registro

Ejemplo: una nota 15 en un conjunto donde los valores esperados se encuentran entre 4 y 9.

A continuación, se visualiza cómo estos gráficos permiten detectar problemas en datos de otro contexto.



4.2 Gráfico de barras

El gráfico de barras **representa valores asociados a variables categóricas o cualitativas**, permitiendo comparar diferentes categorías entre sí. **También puede utilizarse con variables discretas para observar frecuencias o cantidades**.

Es útil para variables como: nombre de estudiantes, materias, categorías, estados (aprobado/desaprobado), etc.

¿Para qué sirve?

- Comparar valores entre diferentes categorías
- Identificar diferencias significativas entre registros
- Detectar comportamientos poco frecuentes

¿Qué anomalías puede mostrar?

- Valores inconsistentes entre categorías
- Registros con valores muy alejados del resto
- Posibles errores en la carga o clasificación de datos

Ejemplo: un estudiante con una nota extremadamente alta o baja respecto al resto del grupo.

A continuación, se muestra como estos gráficos permiten detectar problemas en datos de otro contexto.



4.3 Gráfico de dispersión (scatter)

El gráfico de dispersión **representa la relación entre dos variables cuantitativas**, mostrando cada observación como un punto en el plano. **Permite analizar cómo se relacionan las variables y detectar patrones o tendencias.**

Es útil para analizar relaciones como: horas de estudio vs nota, edad vs rendimiento, etc.

¿Para qué sirve?


- Identificar tendencias (positiva, negativa o nula)
- Analizar relaciones entre variables
- Detectar comportamientos anómalos

¿Qué anomalías puede mostrar?

- Valores atípicos que no siguen la tendencia general
- Relación inconsistente entre variables
- Posibles errores en los datos

Ejemplo: un estudiante con pocas horas de estudio y una nota muy alta, cuando la tendencia general

A continuación, se muestra un gráfico de dispersión permiten detectar problemas en datos de otro contexto.



4.4 Síntesis

La incorporación de representaciones gráficas en la etapa de preparación de datos posibilita la detección temprana de inconsistencias, valores atípicos y errores en los conjuntos de datos. Esto contribuye a minimizar interpretaciones erróneas y a fortalecer la calidad, validez y confiabilidad de los resultados obtenidos en el proceso de minería de datos.

La **preparación de datos** desempeña un papel fundamental en el proceso de descubrimiento de conocimiento, ya que condiciona directamente la **calidad de los patrones identificados** y la **validez de las conclusiones** obtenidas.

Antes de aplicar técnicas de análisis o algoritmos de minería de datos, es necesario asegurar que los datos se encuentren **limpios, completos, consistentes y adecuadamente transformados**. De lo contrario, los resultados pueden reflejar errores o inconsistencias propias de los datos, en lugar de representar comportamientos reales del fenómeno estudiado.

Una adecuada preparación de datos permite:

- **Detectar patrones reales**, evitando que el análisis se vea influenciado por ruido o errores en los datos.
- **Evitar conclusiones erróneas**, que pueden surgir a partir de información incompleta o incorrecta.
- **Mejorar la precisión de los análisis**, al trabajar con datos más confiables y consistentes.

- **Facilitar la interpretación de los resultados**, permitiendo comprender de manera más clara los comportamientos identificados.

En este sentido, la preparación de datos no solo mejora la calidad técnica del análisis, sino que también contribuye a una **mejor toma de decisiones basada en evidencia**.

4.1 Ejemplo aplicado de la importancia de preparación de los datos

Para ilustrar este impacto, consideremos un conjunto de datos correspondiente a las **notas de estudiantes**.

En un escenario donde los datos no han sido previamente preparados, pueden existir errores de carga, valores atípicos o inconsistencias. En este caso, el análisis podría conducir a la siguiente interpretación:

👉 "Las notas de los estudiantes presentan una alta variabilidad."

Sin embargo, luego de aplicar un proceso de **limpieza y validación de los datos**, eliminando errores y corrigiendo inconsistencias, la interpretación puede modificarse significativamente:

👉 "Las notas de los estudiantes son consistentes, y la variabilidad observada se debe principalmente a errores en la carga de datos."

Este ejemplo pone en evidencia que la preparación de los datos no solo mejora la calidad del análisis, sino que puede **cambiar sustancialmente las conclusiones**, permitiendo identificar patrones que realmente representan la realidad estudiada.

A lo largo de esta unidad se abordaron los aspectos fundamentales de la **preparación de datos**, comprendiendo que no se trata de una etapa accesorio dentro del proceso de análisis, sino de un **componente central y determinante** en la generación de conocimiento.

Se analizó la importancia de la **calidad de los datos**, así como las principales problemáticas que pueden presentarse, tales como **datos faltantes**, **datos atípicos** e **inconsistencias**. Asimismo, se exploraron distintas estrategias para su tratamiento, incluyendo la **limpieza**, la **imputación de valores** y la **transformación de variables**, destacando la necesidad de tomar decisiones fundamentadas según el **contexto del problema** y el **tipo de datos involucrados**.

En este sentido, se puso en evidencia que los datos no son un insumo neutral: su estado inicial condiciona el tipo de análisis que puede realizarse y la **calidad de los patrones que pueden descubrirse**. Un conjunto de datos mal preparado puede conducir a **interpretaciones erróneas**, mientras que un dataset adecuadamente tratado permite obtener resultados **más precisos, confiables y significativos**.

De este modo, la preparación de datos se consolida como una etapa clave dentro del proceso KDD, ya que constituye el **punto entre los datos en bruto y el conocimiento útil**.

Se invita a reflexionar que, antes de aplicar cualquier técnica o herramienta, es necesario preguntarse:
¿Qué tan confiables son los datos con los que estoy trabajando?

Esta pregunta no solo orienta el análisis, sino que define su **alcance, validez y utilidad**.

Finalmente, comprender y aplicar adecuadamente los procesos de preparación de datos permitirá desarrollar una mirada más crítica y rigurosa frente al análisis de información, sentando las bases para avanzar hacia etapas posteriores de la minería de datos con mayor solidez conceptual y práctica.

Autoevaluación – Preparación de datos

Consigna: Lee el siguiente conjunto de datos y respondé las preguntas.

id	nombre	nota	hs_estudio
1	Ana	8	5
2	Juan		2
3	Sofía	9	6
4	Pedro	15	1
5	Lucía	7	

Responde estas preguntas:

- ¿Hay datos faltantes? ¿En qué columnas?
- ¿Hay algún valor que te parezca incorrecto o fuera de rango? ¿Cuál?
- ¿Qué problema tiene el registro de Juan?
- ¿Qué harías con el valor de nota = 15?
- ¿Qué harías con el valor faltante en "horas_estudio"?
- ¿Creés que estos datos se pueden analizar directamente? ¿Por qué?

- Menciona al menos dos acciones que harías para preparar estos datos.
- ¿Por qué es importante limpiar los datos antes de analizarlos?