

Unidad Nro. 4: Exploración de relación entre variables

Sitio: [Instituto Superior Politécnico Córdoba](#)

Curso: Minería de Datos - TSCDIA - 2024

Libro: Unidad Nro. 4: Exploración de relación entre variables

Imprimido por: Gaston Dario Alberto DI CAMPLI PEREZ

Día: miércoles, 10 junio 2026, 12:37 PM

Tabla de contenidos

1. Introducción - Unidad IV
2. Análisis bivalente
3. Diagramas de Dispersión
4. Correlación
5. Identificación de tendencias y comportamientos
6. Diferencia entre correlación y causalidad
7. Análisis e interpretación de resultados a partir de gráficos
8. Cierre de la unidad
9. Autoevaluación

En el proceso de **minería de datos**, analizar una sola variable no siempre es suficiente para comprender la información. En muchos casos, es necesario estudiar **cómo se relacionan las variables entre sí**, lo que permite obtener una visión más completa de los datos.

En este contexto, el **análisis bivariado** permite explorar la relación entre dos variables, identificar tendencias y reconocer posibles patrones en los datos.

Esta unidad tiene como objetivo abordar los aspectos fundamentales del análisis bivariado, considerando:

- Gráficos para representar este tipo de análisis: Diagramas de dispersión (scatter plots)
- Concepto de correlación (positiva, negativa, nula)
- Identificación de tendencias y comportamientos
- Diferencia entre correlación y causalidad
- Análisis e interpretación de resultados a partir de gráficos

Objetivos de aprendizaje

Al finalizar esta unidad, el estudiante será capaz de:

- Interpretar gráficos de dispersión
- Reconocer tipos de correlación
- Identificar patrones en los datos

- Diferenciar entre correlación y causalidad
- Interpretar resultados de manera crítica

En la etapa de **exploración de datos**, el análisis univariado permite comprender el comportamiento de cada variable de manera **individual**, identificando su distribución, sus valores representativos y posibles anomalías.

Sin embargo, **en muchos casos, el análisis de una única variable no resulta suficiente** para comprender completamente la información. Para profundizar en el estudio de los datos, **es necesario avanzar hacia el análisis de la relación entre variables**.

En este contexto, **el análisis bivariado constituye el siguiente nivel de estudio, ya que permite examinar la relación entre dos variables**, aportando una comprensión más completa del fenómeno analizado.

2.1 Concepto

El **análisis bivariado es el proceso de estudiar simultáneamente dos variables con el objetivo de identificar posibles relaciones, asociaciones o dependencias entre ellas**.

Este tipo de análisis permite responder preguntas como:

- ¿Existe relación entre las variables?
- ¿Cómo cambia una variable en función de la otra?
- ¿Se observa alguna tendencia?

A diferencia del análisis univariado, que describe una variable de forma aislada, el análisis bivariado se centra en la interacción entre variables.

2.2 Importancia en la exploración de datos

El análisis bivariado **resulta fundamental en la exploración de datos, ya que permite ir más allá de la descripción individual de las variables y comenzar a comprender cómo se relacionan entre sí**.

Por ejemplo, conocer la distribución de las notas de un grupo de estudiantes es útil, pero analizar la relación entre las horas de estudio y las notas permite obtener información más significativa.

En este sentido, el análisis bivariado permite:

- Detectar relaciones entre variables
- Identificar tendencias (positivas, negativas o nulas)
- Descubrir patrones no evidentes en el análisis univariado
- Profundizar la comprensión de los datos

2.3 Representación gráfica

En el análisis bivariado, los gráficos constituyen una herramienta central, ya que permiten **visualizar la relación entre dos variables de manera clara e intuitiva**. A diferencia de los valores numéricos, las representaciones gráficas facilitan la comprensión del comportamiento conjunto de los datos y permiten identificar patrones que no siempre son evidentes a simple vista.

Uno de los gráficos más utilizados es el **gráfico de dispersión (scatter plot)**, que representa la **relación entre dos variables cuantitativas** mediante puntos en un plano. Cada punto refleja una observación y permite analizar cómo varían ambas variables en conjunto.

Este tipo de gráfico permite identificar distintos aspectos clave:

- La **tendencia de la relación**, es decir, si las variables presentan una relación positiva, negativa o nula.
- La **forma de la relación**, que puede ser lineal o no lineal.
- La **intensidad o fuerza de la relación**, según la cercanía o dispersión de los puntos.
- La presencia de **agrupamientos o clusters**, que pueden indicar subgrupos dentro de los datos.
- La detección de **valores atípicos (outliers)** que no siguen el comportamiento general.

De este modo, el gráfico de dispersión no solo permite visualizar los datos, sino también **interpretar cómo se relacionan las variables y detectar comportamientos relevantes**.

Cuando el análisis involucra variables de distinto tipo, también pueden utilizarse otros gráficos. En el caso de combinar una variable cualitativa con una cuantitativa, se emplean **gráficos de barras agrupadas o comparativas**, que permiten observar cómo varía una variable numérica entre distintas categorías.

Estos gráficos permiten:

- **Comparar valores entre grupos**
- Identificar **diferencias significativas entre categorías**
- Detectar **patrones asociados a cada grupo**

Ejemplo: Si se analiza la relación entre la *carrera* (variable cualitativa) y el *promedio de notas* (variable cuantitativa), un gráfico de barras agrupadas permite comparar visualmente los promedios de cada carrera. De esta manera, es posible identificar qué grupo presenta valores más altos o más bajos, y detectar diferencias relevantes entre ellos.

En síntesis, la representación gráfica en el análisis bivariado permite **explorar, interpretar y comunicar la relación entre variables**, facilitando la identificación de tendencias, diferencias y anomalías en los datos.

2.4 Proyección hacia análisis más complejos

El **análisis bivariado constituye un paso intermedio dentro del proceso de exploración de datos**. A partir de este nivel, es posible avanzar hacia estudios más complejos que involucren múltiples variables.

Este tipo de análisis, **conocido como análisis multivariado**, permite estudiar simultáneamente más de dos variables, e incluso representar la información en espacios de mayor dimensión (por ejemplo, representaciones en tres dimensiones).

Estos enfoques serán abordados en el siguiente capítulo.

El **gráfico de dispersión**, introducido en la unidad anterior, constituye una de las herramientas más importantes dentro del **análisis bivariado**. Mientras que previamente fue utilizado para visualizar datos, en esta etapa su uso se orienta principalmente a la **interpretación de la relación entre variables**.

Este tipo de gráfico permite analizar el comportamiento conjunto de dos variables cuantitativas, facilitando la identificación de patrones y tendencias que no pueden observarse a partir del análisis individual de cada variable.

3.1 Análisis del gráfico de dispersión

El valor principal del gráfico de dispersión radica en su capacidad para proporcionar información sobre distintos aspectos de la relación entre variables.

En primer lugar, **permite identificar la dirección de la relación**, es decir, **si las variables presentan un comportamiento creciente (relación positiva), decreciente (relación negativa) o si no se observa un patrón definido (relación nula)**.

Asimismo, **la dispersión de los puntos permite evaluar la intensidad o fuerza de la relación**. Cuando los puntos se encuentran próximos entre sí y siguen una tendencia clara, se habla de una relación fuerte; en cambio, cuando se encuentran dispersos, la relación es débil.

Otro aspecto relevante es la forma de la relación, que puede ser **lineal**, cuando los datos siguen una tendencia recta, o **no lineal**, cuando presentan comportamientos más complejos.

Además, **el gráfico permite detectar la presencia de valores atípicos (outliers)**, es decir, observaciones que se alejan del patrón general y que pueden corresponder a errores en los datos o a situaciones particulares que requieren análisis adicional.

3.2 Limitaciones del gráfico de dispersión

Si bien el gráfico de dispersión es una herramienta poderosa, presenta ciertas limitaciones que deben ser consideradas.

En primer lugar, permite identificar relaciones entre variables, pero no permite establecer relaciones de causalidad. Es decir, que dos variables estén relacionadas no implica que una sea causa de la otra.

Asimismo, **la interpretación puede verse afectada por:**

La presencia de pocos datos

Valores atípicos

Variables no consideradas (variables ocultas)

Por este motivo, el análisis debe realizarse de manera crítica y complementarse con otras herramientas.

En el **análisis bivariado**, el **gráfico de dispersión** permite identificar visualmente la existencia de una **relación entre variables**. Sin embargo, para comprender esta relación con mayor precisión, es necesario contar con una herramienta que permita medirla.

En este contexto, **la correlación permite expresar de manera numérica el grado de asociación entre dos variables**.

4.1 Correlación

La **correlación es una medida estadística que indica el grado en que dos variables se relacionan entre sí**, es decir, cómo varía una variable en función de la otra.

Esta relación **puede ser positiva**, cuando ambas variables aumentan o disminuyen conjuntamente; **negativa**, cuando una variable aumenta mientras la otra disminuye; o **nula**, cuando no se observa una relación aparente.

Además, la correlación permite analizar la intensidad de la relación entre las variables.

4.2 Valores de la correlación

La **correlación se expresa mediante un coeficiente que toma valores entre -1 y 1**.

Valores cercanos a 1 indican una relación positiva fuerte, mientras que valores cercanos a -1 indican una relación negativa fuerte. Por el contrario, valores próximos a 0 indican ausencia de relación.

En términos generales, valores superiores a 0.7 (o inferiores a -0.7) indican relaciones fuertes, valores intermedios relaciones moderadas y valores cercanos a 0 relaciones débiles.

La correlación permite complementar el análisis visual, proporcionando una medida concreta de la relación entre variables.

Por ejemplo, un valor de 0.78 indica una relación positiva fuerte, mientras que un valor de -0.65 indica una relación negativa moderada. Un valor cercano a cero indica que no existe una relación significativa entre las variables.


4.3 Ejemplo caso práctico

Se desea analizar la relación entre la **cantidad de horas que los estudiantes utilizan redes sociales por día** y la **nota obtenida en un examen**.

Para ello, se cuenta con el siguiente conjunto de datos:

Estudiante	Hs en redes	Nota
A	1	9
B	2	8
C	3	7
D	4	6
E	5	5
F	6	4

A partir de estos datos, se construye un **gráfico de dispersión**, en el cual cada punto representa un estudiante, ubicando las horas de uso de redes en el eje horizontal y la nota en el eje vertical.



Al observar el gráfico, se aprecia que los puntos siguen una **tendencia descendente**, lo que indica que, a medida que aumentan las horas dedicadas a redes sociales, la nota tiende a disminuir. Además, los puntos se encuentran relativamente alineados, lo que sugiere que la relación entre las variables es fuerte.

Para cuantificar esta relación, se calcula el **coeficiente de correlación**, obteniendo un valor aproximado de **-0.97**.

Este valor indica que existe una **correlación negativa muy fuerte** entre las variables, es decir, cuando una aumenta, la otra tiende a disminuir de manera significativa.

En función de este análisis, **se puede interpretar que existe una asociación clara entre el uso de redes sociales y el rendimiento académico. Sin embargo, es importante destacar que esta relación no implica causalidad directa, ya que pueden intervenir otros factores que influyan en el resultado.**

En el análisis bivariado, uno de los aspectos centrales es la identificación de **tendencias y comportamientos en los datos**, ya que permiten comprender de qué manera las variables se relacionan entre sí y cómo evolucionan en conjunto.

A partir del **gráfico de dispersión** y del **coeficiente de correlación**, es posible analizar no solo la existencia de una relación, sino también sus características principales.

En primer lugar, se pueden identificar distintos tipos de **tendencias**:

- **Tendencia creciente (positiva)**: ambas variables aumentan o disminuyen conjuntamente
- **Tendencia decreciente (negativa)**: una variable aumenta mientras la otra disminuye
- **Ausencia de tendencia**: no se observa un patrón claro en la relación

Sin embargo, el análisis no se limita únicamente a la dirección de la relación. Es fundamental profundizar en el **comportamiento de los datos**, considerando diversos aspectos que enriquecen la interpretación.

En este sentido, es posible analizar:

- La **concentración o dispersión de los puntos**, que permite evaluar la **intensidad o fuerza de la relación**
- La presencia de **agrupamientos (clusters)**, que pueden indicar la existencia de subgrupos con comportamientos diferenciados
- La existencia de **valores atípicos (outliers)**, que se alejan del patrón general y pueden influir en el análisis

Asimismo, es importante considerar la **forma de la relación**, ya que los datos pueden seguir un comportamiento **lineal** o presentar patrones más complejos de tipo **no lineal**.

El análisis conjunto de estos elementos permite comprender no solo si existe una relación entre las variables, sino también **cómo se manifiesta dicha relación**, aportando información clave para una interpretación más profunda y fundamentada de los datos.

5.1 Interpretación de la relación entre variables

La interpretación de la **relación entre variables constituye una de las etapas más críticas del análisis bivariado**, ya que implica trascender la observación gráfica y la medición estadística para **construir significado a partir de los datos**.

Mientras que herramientas como el **gráfico de dispersión** y el **coeficiente de correlación** permiten identificar la existencia, dirección e intensidad de una relación, la interpretación requiere integrar estos elementos dentro de un **marco contextual y analítico más amplio**.

En este sentido, interpretar una relación implica analizar de manera conjunta múltiples dimensiones:

5.1.1 Dirección de la relación

Permite establecer si las variables evolucionan de manera directa (positiva), inversa (negativa) o si no presentan una relación evidente. Este aspecto describe el sentido general del comportamiento conjunto.

5.1.2 Intensidad o fuerza

Refiere al grado en que las variables se relacionan. Una correlación fuerte indica una asociación consistente, mientras que una débil sugiere mayor variabilidad o menor dependencia entre las variables.

5.1.3 Forma de la relación

No todas las relaciones son lineales. Es posible identificar patrones no lineales (curvilíneos, exponenciales, etc.), lo cual requiere un análisis más cuidadoso, ya que puede invalidar interpretaciones basadas únicamente en la correlación lineal.

5.1.4 Consistencia del patrón

Hace referencia a la estabilidad del comportamiento observado. La dispersión de los puntos permite evaluar si la relación es homogénea o si presenta variaciones significativas en distintos rangos de los datos.

5.1.5 Influencia de valores atípicos

Los outliers pueden distorsionar tanto la visualización como el cálculo de la correlación, generando interpretaciones engañosas. Su identificación y análisis son esenciales para validar conclusiones.

5.1.6 Contexto del problema

La interpretación no puede realizarse de manera aislada. Es imprescindible considerar el dominio del problema, el origen de los datos y las condiciones en las que fueron obtenidos, ya que estos factores condicionan el significado de la relación observada.

5.1.7 Integración de los elementos

Una interpretación adecuada no se basa en un único indicador, sino en la articulación de todos los aspectos analizados. En este sentido, una relación puede ser:

Fuerte pero no relevante en el contexto del problema
Débil pero significativa en determinados escenarios
Aparente, debido a la presencia de variables no consideradas

Por lo tanto, interpretar implica evaluar críticamente la información disponible, evitando conclusiones simplistas o generalizaciones indebidas.

5.1.8 Hacia una interpretación fundamentada

El objetivo final del análisis bivariado no es únicamente identificar relaciones, sino explicar y comprender los fenómenos observados. Esto requiere:

Analizar los datos desde múltiples perspectivas
Cuestionar los resultados obtenidos
Validar la coherencia de las conclusiones

En este marco, la interpretación se posiciona como un proceso analítico, crítico y contextualizado, fundamental para transformar los datos en conocimiento útil para la toma de decisiones.

En el análisis de datos, uno de los errores más frecuentes consiste en asumir que la existencia de una relación entre variables implica necesariamente una relación de causa y efecto. Sin embargo, es fundamental comprender que **correlación no implica causalidad**.

El hecho de que dos variables presenten una asociación, ya sea positiva o negativa, indica que existe un comportamiento conjunto, pero no permite afirmar que una variable sea la causa directa de la otra. La correlación mide **cómo varían las variables en conjunto**, pero no explica el motivo de dicha variación.

En muchos casos, la relación observada puede estar influenciada por **variables externas no consideradas** (variables ocultas o de confusión), que afectan simultáneamente a las variables analizadas.

Por ejemplo, puede observarse una relación entre el aumento en la venta de helados y el incremento en ciertos incidentes. Sin embargo, ambas variables pueden estar relacionadas con una tercera variable, como la temperatura, que influye en ambas situaciones.

Asimismo, pueden existir relaciones **espurias**, es decir, asociaciones aparentes que no tienen un fundamento real y que surgen por coincidencias en los datos o por estructuras subyacentes no analizadas.

Por este motivo, establecer relaciones de causalidad requiere un análisis más profundo, que incluye:

- Considerar el contexto del problema
- Analizar posibles variables intervinientes
- Evaluar la dirección temporal de los fenómenos
- Validar hipótesis mediante métodos adicionales

En este sentido, el análisis bivariado permite **identificar relaciones**, pero no es suficiente para explicar causas.

Comprender esta diferencia es fundamental para evitar interpretaciones erróneas y desarrollar un pensamiento crítico en el análisis de datos.

6.1 Ejemplo práctico

Supóngase que, al analizar un conjunto de datos, se observa una relación entre:

- **Cantidad de horas de uso del celular**
- **Nivel de cansancio durante el día**

El análisis muestra que, a mayor uso del celular, mayor es el nivel de cansancio. En este sentido, puede afirmarse que **se ha identificado una relación entre las variables**.

Sin embargo, esta observación no es suficiente para establecer una relación de causalidad. Es posible que exista una **variable interviniente**, como la falta de sueño, que explique ambos fenómenos: las personas que duermen menos tienden a usar más el celular y, al mismo tiempo, presentan mayor cansancio.

De este modo, si bien se ha detectado una relación válida desde el análisis de datos, **su interpretación debe realizarse con cautela**.

A partir de la relación identificada, el análisis debería avanzar hacia una instancia más profunda, que permita comprender el fenómeno de manera más completa.

Esto implica:

- Incorporar variables adicionales relevantes, como la cantidad de horas de sueño
- Evaluar si la relación se mantiene al considerar estos factores
- Analizar el contexto en el que se generan los datos
- Formular hipótesis y validarlas mediante un análisis más completo

En este sentido, identificar una relación constituye un primer paso, pero **explicar sus causas requiere un análisis más amplio y fundamentado**.

En el análisis de datos, los gráficos no solo cumplen una función descriptiva, sino que constituyen una herramienta central para la **exploración, análisis e interpretación de la información**. Su valor radica en la capacidad de sintetizar grandes volúmenes de datos en representaciones visuales que permiten identificar patrones, tendencias y relaciones de manera más eficiente.

Sin embargo, el uso de gráficos no garantiza por sí mismo una correcta comprensión de los datos. La interpretación adecuada requiere un proceso analítico que integre múltiples dimensiones y evite conclusiones superficiales.

7.1 Análisis de la información representada

El análisis a partir de gráficos implica examinar de manera sistemática distintos aspectos de la información visualizada. En este sentido, es necesario considerar:

- La **tendencia general** de los datos, identificando si existe un patrón creciente, decreciente o ausencia de tendencia
- La **dispersión o variabilidad**, que permite evaluar la estabilidad del comportamiento observado
- La presencia de **valores atípicos**, que pueden alterar la interpretación
- La existencia de **agrupamientos o patrones diferenciados**, que pueden indicar subpoblaciones dentro del conjunto de datos

Este análisis permite transformar una representación visual en información significativa.

7.2 Integración con el análisis estadístico

Una interpretación rigurosa no debe basarse únicamente en la observación visual. Es fundamental complementar el análisis gráfico con herramientas estadísticas, como la correlación o medidas descriptivas, que permitan **validar y cuantificar los patrones observados**.

En este sentido, los gráficos y las medidas estadísticas deben entenderse como herramientas complementarias:

- El gráfico permite **visualizar y explorar**
- Las medidas permiten **confirmar y cuantificar**

7.3 Limitaciones y posibles sesgos

Uno de los aspectos más importantes en el análisis de gráficos es reconocer sus limitaciones. Las representaciones visuales pueden inducir a interpretaciones erróneas si no se analizan críticamente.

Entre los principales aspectos a considerar se encuentran:

- **Escalas inadecuadas**, que pueden exagerar o minimizar diferencias
- **Selección parcial de datos**, que puede sesgar la interpretación
- **Diseños gráficos confusos o poco claros**
- **Exceso de simplificación**, que oculta la complejidad de los datos

Por este motivo, el análisis gráfico debe realizarse con precaución, evitando conclusiones apresuradas.

7.4 Interpretación en contexto

La interpretación de los resultados no puede realizarse de manera aislada. Es imprescindible considerar el **contexto del problema**, el origen de los datos y las condiciones en las que fueron obtenidos.

Un mismo gráfico puede tener interpretaciones diferentes según el contexto en el que se analice. Por ello, el análisis debe integrar tanto la información visual como el conocimiento del dominio.

7.5 Hacia una interpretación crítica

El análisis a partir de gráficos no consiste únicamente en describir lo que se observa, sino en **interpretar, cuestionar y validar la información**.

Esto implica:

- Formular hipótesis a partir de los patrones observados
- Evaluar la consistencia de los resultados
- Identificar posibles explicaciones alternativas
- Evitar inferencias no justificadas

En este sentido, el uso de gráficos se transforma en una herramienta para el **pensamiento crítico**, más que en un simple recurso visual.

A lo largo de esta unidad se abordó el análisis de la **relación entre variables**, profundizando en el enfoque bivariado como una herramienta fundamental para comprender el comportamiento conjunto de los datos.

Se trabajó con el **gráfico de dispersión** como recurso central para visualizar relaciones, incorporando posteriormente el concepto de **correlación** como medida que permite cuantificar la intensidad y dirección de dichas relaciones.

Asimismo, se avanzó en la **identificación de tendencias y comportamientos**, así como en la **interpretación de la relación entre variables**, integrando aspectos como la dirección, la intensidad, la forma y la presencia de valores atípicos.

Un eje clave de la unidad fue la comprensión de la **diferencia entre correlación y causalidad**, destacando la importancia de evitar interpretaciones erróneas y de considerar el contexto, las variables intervinientes y las limitaciones del análisis.

Finalmente, se abordó el **análisis e interpretación a partir de gráficos**, entendiendo que las representaciones visuales no solo permiten observar los datos, sino también analizarlos de manera crítica y fundamentada.

En conjunto, estos contenidos permiten comprender que el análisis bivariado no se limita a identificar relaciones, sino que implica **interpretar, cuestionar y validar la información**, constituyendo un paso esencial en el proceso de minería de datos.

Consigna: Respondé brevemente utilizando los conceptos trabajados en la unidad.

Preguntas

1. ¿Qué aporta el análisis bivariado que no se puede observar en un análisis univariado?
2. ¿Qué indica que los puntos en un gráfico de dispersión estén muy concentrados o muy dispersos?
3. ¿Por qué no es correcto afirmar que una variable causa a otra solo porque están relacionadas?
4. ¿Qué aspectos deberías considerar antes de interpretar una relación entre variables?