

# Unidad Nro. 5: Introducción a las técnicas de minería de datos

Sitio: [Instituto Superior Politécnico Córdoba](https://www.ispc.edu.ar)

Curso: Minería de Datos - TSCDIA - 2024

Libro: Unidad Nro. 5: Introducción a las técnicas de minería de datos

Imprimido por: Gaston Dario Alberto DI CAMPLI PEREZ

Día: miércoles, 10 junio 2026, 12:39 PM

## Tabla de contenidos

1. Introducción - Unidad V
2. Concepto de predicción
3. Técnicas de minería de datos
4. Clasificación
5. Regresión
6. Interpretación de resultados - Clasificación
7. Interpretación de resultados - Regresión
8. Métricas de evaluación en Clasificación
9. Métricas de evaluación en Regresión
10. Cierre de la unidad

En el proceso de análisis de datos, una etapa fundamental es la **exploración y visualización de los datos**, ya que permite comprender su estructura, detectar patrones iniciales y preparar la información para su posterior análisis.

En el marco del proceso **KDD (Knowledge Discovery in Databases)**, esta etapa se ubica principalmente en las fases de **preprocesamiento y transformación**, donde los datos son organizados y analizados antes de aplicar técnicas de minería de datos.

La exploración de datos permite identificar problemas como valores faltantes, errores o datos atípicos, mientras que la visualización facilita la **interpretación y comunicación de la información**.

En esta unidad se abordarán herramientas ampliamente utilizadas en el ámbito profesional, como Excel/Google Sheets, Google Looker Studio y Microsoft Power BI.

En este contexto, se analizará cómo estas herramientas permiten explorar, visualizar e interpretar los datos, facilitando su transformación en información significativa para la toma de decisiones.

***¡Comencemos a explorar cómo los datos pueden transformarse en conocimiento útil!***

La **predicción consiste en estimar el valor de una variable a partir de la información disponible en otras variables**. En el contexto de la minería de datos, implica construir modelos que, a partir de datos históricos, sean capaces de inferir comportamientos futuros o desconocidos.

Por ejemplo, a partir de variables como horas de estudio, asistencia y participación, es posible predecir el rendimiento académico de un estudiante.

La predicción no garantiza resultados exactos, sino que ofrece **estimaciones basadas en patrones identificados en los datos**.

## 2.1 Ejemplo de predicción

Supongamos que se cuenta con información de estudiantes que incluye:

- Horas de estudio
- Asistencia a clases
- Participación en actividades
- Nota final obtenida

A partir de estos datos, es posible construir un modelo que permita **predecir la nota final de un estudiante** en función de sus características. Por ejemplo, un estudiante que:

- estudia 6 horas por semana
- tiene alta asistencia
- participa en clase

A partir del análisis de estos datos históricos, el **modelo puede identificar patrones**, como por ejemplo que los **estudiantes con mayor cantidad de horas de estudio y alta asistencia tienden a obtener mejores resultados académicos**. En base a estos patrones, **si se analiza un nuevo estudiante que presenta características similares, el modelo puede estimar cuál sería su rendimiento esperado**.

Por ejemplo, un estudiante que estudia regularmente, asiste a la mayoría de las clases y participa activamente podría tener una **nota estimada alta**, mientras que un estudiante con baja asistencia y pocas horas de estudio podría presentar un rendimiento esperado menor.

En este sentido, **la predicción no implica conocer con certeza el resultado final, sino generar una estimación basada en comportamientos observados previamente en los datos**.

En esta unidad se **abordarán diversas técnicas de la minería de datos que permiten realizar este tipo de predicciones a partir del análisis de los datos**. A través de estas herramientas, será posible identificar patrones, estimar resultados y comprender comportamientos, lo cual resulta fundamental para la toma de decisiones informadas basadas en evidencia.

La minería de datos comprende un conjunto de técnicas que permiten analizar grandes volúmenes de información con el objetivo de **descubrir patrones, relaciones y generar modelos** que faciliten la comprensión y predicción de fenómenos.

Estas técnicas constituyen herramientas fundamentales dentro del proceso de análisis de datos, ya que permiten avanzar desde la simple descripción de la información hacia la **generación de conocimiento útil y la toma de decisiones informadas**.

## 3.1 Clasificación de las técnicas de minerías de datos

De manera general, las técnicas de minería de datos pueden clasificarse en dos grandes grupos según el objetivo del análisis:

### 3.1.1 Técnicas descriptivas

Tienen como objetivo **explorar y describir la estructura de los datos**, sin realizar predicciones. Permiten identificar patrones, relaciones o agrupamientos que no son evidentes a simple vista.

Entre las principales se encuentran:

- **Clustering (agrupamiento):** Permite agrupar datos en función de su similitud, identificando segmentos o grupos dentro de un conjunto de datos.
- **Reglas de asociación:** Permiten descubrir relaciones frecuentes entre variables, como por ejemplo productos que suelen comprarse juntos.

### 3.1.2 Técnicas predictivas

Tienen como objetivo **estimar o predecir valores futuros o desconocidos** a partir de datos históricos. Estas técnicas construyen modelos que permiten inferir resultados a partir de la información disponible.

Entre las principales se encuentran:

- **Clasificación:** Se utiliza cuando la variable a predecir es categórica. El objetivo es asignar cada caso a una categoría predefinida.

- **Regresión:** Se utiliza cuando la variable a predecir es numérica. El objetivo es estimar un valor continuo.

### 3.2 Enfoque de la unidad

Si bien existen diversas técnicas de minería de datos con distintos objetivos, en esta unidad se pondrá especial énfasis en las **técnicas predictivas**, particularmente en los problemas de **clasificación y regresión**.

Estas técnicas resultan especialmente relevantes en el contexto del análisis de datos, ya que permiten no solo comprender la información disponible, sino también **anticipar comportamientos y apoyar la toma de decisiones** en distintos ámbitos.

Si bien existen diversas técnicas de minería de datos con distintos objetivos, en esta unidad se pondrá especial énfasis en las **técnicas predictivas**, particularmente en los problemas de **clasificación y regresión**.

Estas técnicas resultan especialmente relevantes en el contexto del análisis de datos, ya que permiten no solo comprender la información disponible, sino también **anticipar comportamientos y apoyar la toma de decisiones** en distintos ámbitos.

### 4.1 Técnica de Clasificación

La clasificación es una técnica predictiva cuyo objetivo es **asignar cada caso a una categoría o clase previamente definida**. Se utiliza cuando la variable que se desea predecir es de tipo **cualitativo o categórico**.

En este tipo de problemas, el modelo aprende a partir de ejemplos históricos ya clasificados y, con base en esos patrones, puede predecir a qué categoría pertenecerá un nuevo caso.

En términos simples, clasificar implica responder preguntas del tipo:

- ¿Este estudiante aprobará o desaprobará?
- ¿Este cliente abandonará el servicio o continuará?
- ¿Este correo es spam o no spam?

En todos estos casos, la salida no es un número, sino una **clase**.

La clasificación trabaja con una **variable objetivo categórica**, es decir, una variable cuyos posibles valores representan grupos o etiquetas.

Estas categorías pueden ser:

- **Binarias**, cuando existen solo dos clases posibles  
Ejemplo: aprobado / desaprobado
- **Multiclase**, cuando existen más de dos categorías  
Ejemplo: riesgo bajo / medio / alto

El modelo de clasificación **intenta encontrar regularidades en los datos para determinar qué características permiten diferenciar una clase de otra**.

### 4.2 Funcionamiento general

De manera general, un proceso de clasificación parte de un conjunto de datos en el que ya se conoce la categoría de cada caso. A partir de esta información, el modelo analiza las variables disponibles e identifica patrones que luego utilizará para clasificar nuevos registros.

Por ejemplo, si se dispone de datos históricos de estudiantes con variables como:

- horas de estudio
- asistencia
- participación
- notas parciales

y además se conoce si aprobaron o desaprobaron, el modelo puede aprender qué combinaciones de variables suelen asociarse con cada resultado.

Luego, al analizar un nuevo estudiante, el sistema podrá predecir a qué categoría pertenece.

### 4.3 Ejemplo aplicado

Supóngase que una institución educativa cuenta con información histórica de sus estudiantes y desea anticipar qué alumnos presentan riesgo de desaprobación una materia.

Para ello, se dispone de variables como:

- porcentaje de asistencia
- cantidad de trabajos prácticos entregados
- participación en clase

- resultados de evaluaciones parciales

La variable objetivo en este caso será:

- **Aprobado**
- **Desaprobado**

A partir de los registros anteriores, el modelo de clasificación puede identificar patrones. Por ejemplo, puede detectar que los estudiantes con baja asistencia, pocas entregas y bajo desempeño parcial tienden con mayor frecuencia a desaprobado.

De este modo, si un nuevo estudiante presenta esas características, el modelo puede clasificarlo dentro de la categoría "riesgo de desaprobado".

Este tipo de predicción resulta especialmente útil porque permite **anticipar situaciones problemáticas y tomar decisiones preventivas**, como ofrecer apoyo académico o realizar un seguimiento más cercano.

#### 4.4 Ventajas de la clasificación

La clasificación es especialmente útil cuando se necesita:

- tomar decisiones a partir de categorías claras
- segmentar casos según riesgo, comportamiento o estado
- automatizar procesos de evaluación o selección

Además, suele ser una técnica muy valiosa en contextos donde la decisión final depende de identificar correctamente una clase.

#### 4.5 Ámbitos de aplicación

La clasificación se utiliza en múltiples contextos, por ejemplo:

- **Educación:** aprobado/desaprobado, riesgo académico
- **Salud:** presencia o ausencia de una enfermedad
- **Finanzas:** cliente riesgoso / no riesgoso
- **Marketing:** cliente que compra / no compra
- **Tecnología:** correo spam / no spam

Estos ejemplos muestran que la clasificación resulta adecuada cuando el problema requiere **asignar etiquetas o categorías**.

#### 4.6 Consideraciones importantes

Aunque la clasificación permite construir modelos potentes, su calidad depende de diversos factores, tales como:

- la calidad de los datos
- la representatividad de las categorías
- el equilibrio entre clases
- la selección adecuada de variables

Por este motivo, no basta con aplicar la técnica: es necesario comprender el problema, interpretar los resultados y validar el modelo.

### 5.1 Técnica de regresión

La **regresión** es una técnica predictiva cuyo objetivo es **estimar un valor numérico continuo** a partir de una o más variables explicativas.

Se **utiliza cuando la variable que se desea predecir es de tipo cuantitativo**, es decir, cuando el resultado esperado no es una categoría, sino un número. En este tipo de problemas, el modelo analiza la relación entre variables y construye una función o patrón que permite aproximar un valor para nuevos casos.

En términos simples, la regresión busca responder preguntas como:

- ¿Qué nota final obtendrá un estudiante?
- ¿Cuánto venderá una empresa el próximo mes?
- ¿Cuál será el consumo estimado de energía?

En todos estos casos, la salida es un **valor numérico**.

La regresión trabaja con una **variable objetivo cuantitativa**, cuyos valores representan una magnitud medible. Puede tratarse de:

- una nota
- un precio
- una cantidad
- una temperatura
- un tiempo

El modelo busca identificar cómo varía dicha variable en función de otras, encontrando patrones que permitan realizar estimaciones razonables.

## 5.2 Funcionamiento general

El proceso de regresión parte de un conjunto de datos históricos donde se conocen tanto las variables de entrada como el valor final que se desea predecir.

Por ejemplo, si se dispone de información sobre estudiantes que incluye:

- horas de estudio
- asistencia
- participación
- notas anteriores

y además se conoce la **nota final**, el modelo puede aprender cómo esas variables influyen en el resultado.

Posteriormente, cuando se presenta un nuevo caso, el modelo utiliza ese patrón aprendido para estimar cuál podría ser el valor final esperado.

## 5.3 Ejemplo aplicado

Supóngase que una institución educativa desea estimar la nota final que podría obtener un estudiante antes de rendir su examen final.

Para ello, cuenta con variables como:

- cantidad de horas de estudio semanales
- porcentaje de asistencia
- promedio de trabajos prácticos
- desempeño en evaluaciones parciales

La variable objetivo será en este caso una **nota numérica**, por ejemplo en una escala de 1 a 10.

A partir del análisis de datos históricos, el modelo puede detectar que estudiantes con determinadas combinaciones de asistencia, dedicación y desempeño previo tienden a obtener ciertas notas finales.

Por ejemplo, un estudiante con alta asistencia, buen promedio en trabajos prácticos y resultados parciales positivos podría recibir una **predicción de nota final de 8.2**.

En este caso, el modelo no clasifica al estudiante en una categoría, sino que estima un valor continuo.

Este tipo de resultados permite contar con una referencia anticipada del rendimiento esperado, lo que puede resultar útil para diseñar estrategias de apoyo, detectar situaciones de riesgo o planificar intervenciones pedagógicas.

## 5.4 Diferencia con la clasificación

La **regresión y la clasificación comparten la lógica de construir modelos predictivos, pero se distinguen por la naturaleza de la variable objetivo**.

- En la **clasificación**, el resultado es una categoría
- En la **regresión**, el resultado es un número

Por ejemplo:

- "Aprobado / desaprobado" → clasificación
- "Nota final estimada: 7.8" → regresión

Esta diferencia es central, ya que determina tanto el tipo de técnica a utilizar como la forma de evaluar el modelo.

## 5.5 Ejemplo de aplicación

La regresión se aplica en numerosos contextos, por ejemplo:

- **Educación:** predicción de nota final
- **Negocios:** proyección de ventas
- **Economía:** estimación de ingresos
- **Energía:** consumo esperado
- **Salud:** tiempo estimado de recuperación

Todos estos casos comparten la necesidad de estimar un valor numérico continuo a partir de información disponible.

## 5.6 Ventajas de la regresión

La regresión es especialmente útil cuando se busca:

- estimar resultados cuantitativos

- anticipar comportamientos medibles
- modelar relaciones entre variables
- apoyar decisiones basadas en proyecciones numéricas

Su aporte principal es permitir pasar desde la observación de patrones hacia la **estimación concreta de valores**.

## 5.7 Consideraciones importantes

Como en toda técnica predictiva, la calidad de la regresión depende de factores como:

- la calidad de los datos
- la selección de variables
- la existencia de patrones consistentes
- la adecuada interpretación de los resultados

Además, debe tenerse en cuenta que la predicción obtenida es una **estimación**, no una garantía exacta del valor real.

Una vez construido un modelo predictivo, ya sea de **clasificación o regresión**, una etapa fundamental consiste en **interpretar correctamente sus resultados**.

No alcanza con obtener una predicción: es necesario comprender **qué significa ese resultado, qué tan confiable es y cómo puede utilizarse para la toma de decisiones**.

La interpretación permite transformar el resultado técnico del modelo en **información significativa**, evitando errores de análisis y conclusiones incorrectas.

## 6.1 Interpretación en modelos de clasificación

Un modelo de clasificación genera como resultado una **categoría o clase** para cada caso analizado. Por ejemplo:

- Aprobado / Desaprobado
- Riesgo bajo / medio / alto
- Cliente activo / cliente que abandona

En algunos casos, además de la clase, el modelo puede indicar una **probabilidad asociada** a esa predicción.

Interpretar un resultado de clasificación implica responder:

- ¿A qué categoría fue asignado el caso?
- ¿Con qué nivel de *confianza* se realizó esa asignación?
- ¿Qué variables influyeron en esa decisión?

No se trata solo de ver la etiqueta, sino de comprender **el contexto de la predicción**.

## 6.2 Ejemplo aplicado

Supongamos un modelo que predice el rendimiento académico de estudiantes. A continuación se muestra el resultado del modelo:

- Estudiante: Juan
- Predicción: **Desaprobado**
- Probabilidad: 0.82

El modelo indica que, según los datos analizados, Juan tiene una **alta probabilidad (82%) de desaprobar**. Esto no significa que necesariamente desaprobará, sino que:

- presenta características similares a estudiantes que desaprobaron en el pasado
- existe un riesgo significativo

La interpretación correcta permite tomar decisiones como:

- realizar seguimiento personalizado
- ofrecer tutorías o apoyo académico
- intervenir antes de que ocurra el resultado negativo

Es decir, la clasificación no solo describe, sino que **permite actuar anticipadamente**.

## 6.3 Errores comunes en la interpretación

- Asumir que la predicción es segura (no lo es)
- Ignorar la probabilidad o nivel de confianza
- No considerar el contexto del problema

- Interpretar la predicción como causalidad

## 7.1 Interpretación de resultados en la regresión

Un modelo de regresión genera como resultado un **valor numérico estimado**. Por ejemplo:

- Nota final: 7.8
- Ventas estimadas: 1200 unidades
- Consumo esperado: 350 kWh

Este valor representa una **aproximación basada en patrones históricos**. Interpretar un resultado de regresión implica analizar:

- el valor estimado
- qué tan razonable es ese valor
- el margen de error posible
- el contexto en el que se aplica

El resultado debe entenderse como una **estimación, no un valor exacto**.

## 7.2 Ejemplo aplicado

Supongamos un modelo que estima la nota final de un estudiante. A continuación, se muestra el resultado del modelo:

- Estudiante: María
- Nota estimada: **8.2**

El modelo indica que, según su comportamiento (asistencia, parciales, trabajos), María probablemente obtenga una nota cercana a 8. Esto implica que:

- presenta un desempeño consistente con estudiantes que obtuvieron notas similares
- su rendimiento esperado es alto

La interpretación permite:

- anticipar desempeño académico
- detectar estudiantes con bajo rendimiento esperado
- ajustar estrategias de enseñanza o acompañamiento

En este caso, el valor numérico permite **proyectar resultados y planificar acciones**.

## 7.3 Errores comunes en la interpretación

- Tomar el valor como exacto
- No considerar posibles variaciones
- Ignorar factores no incluidos en el modelo
- Extrapolar fuera del contexto de los datos

## 7.4 Síntesis

Interpretar correctamente los resultados de modelos predictivos es tan importante como construirlos. Un modelo puede ser técnicamente correcto, pero si sus resultados se interpretan de forma errónea, las decisiones tomadas pueden ser inadecuadas.

Por este motivo, el análisis de resultados debe realizarse siempre de manera crítica, considerando:

- el contexto del problema
- la calidad de los datos
- las limitaciones del modelo

Una vez construido un modelo de clasificación o regresión, es fundamental evaluar **qué tan bien funciona**. La evaluación permite determinar si las predicciones del modelo son **confiables, útiles y adecuadas para la toma de decisiones**.

En este sentido, no alcanza con que un modelo genere resultados: es necesario medir **su desempeño** mediante métricas específicas.

## 8.1 Evaluación en los modelos de clasificación

En clasificación, el objetivo es analizar **qué tan bien el modelo asigna correctamente las categorías**. Es decir, ¿Cuántas predicciones fueron correctas y cuántas no?.

Para evaluar un modelo de clasificación, se comparan:

- la **clase real** (lo que realmente ocurrió)
- la **clase predicha** (lo que el modelo dijo)

A partir de esta comparación surgen cuatro situaciones:

- **Verdaderos positivos (VP):** predijo correctamente un caso positivo
- **Verdaderos negativos (VN):** predijo correctamente un caso negativo
- **Falsos positivos (FP):** predijo positivo, pero era negativo
- **Falsos negativos (FN):** predijo negativo, pero era positivo

## 8.2 Métricas principales

**Exactitud (Accuracy):** Indica el porcentaje de predicciones correctas sobre el total. Ejemplo: Si un modelo acierta 80 de 100 casos → accuracy = 80%. Esto se puede interpretar como la medición del rendimiento general, pero puede ser engañoso si hay clases desbalanceadas.

**Precisión (Precision):** Mide qué proporción de los casos predichos como positivos realmente lo son. Por ejemplo, si el modelo predice 20 estudiantes en riesgo, pero solo 15 realmente lo están, el resultado sería:

$$\text{Precision} = 15 / 20 = 75\%$$

Este indicador refleja que tan confiables son las predicciones positivas.

**Recall (Sensibilidad):** Mide qué proporción de los casos positivos reales fueron correctamente detectados. Por ejemplo, si hay 30 estudiantes en riesgo y el modelo detecta 15:

$$\text{Recall} = 15 / 30 = 50\%$$

Este indicador refleja la capacidad del modelo para **detectar casos importantes**.

**F1-Score:** Es una medida que combina precisión y recall. Se utiliza cuando se busca un equilibrio entre:

- no cometer errores (precisión)
- no dejar casos sin detectar (recall)

## 8.3 Caso aplicado: métricas en clasificación

Supongamos un modelo que predice si un estudiante desaprobará:

- Total estudiantes: 100
- Desaprobados reales: 30
- Detectados correctamente: 24
- Detectados incorrectamente: 6

Interpretación:

- El modelo detecta muchos casos reales (buen recall)
- Tiene cierto margen de error (precision moderada)

Esto permite decidir si el modelo es útil para intervenir académicamente.

## 9.1 Evaluación en los modelos de regresión

En regresión, el objetivo es medir **qué tan cerca están los valores predichos de los valores reales**. No se trata de aciertos o errores categóricos, sino de **diferencias numéricas**. El **error** es la **diferencia** entre el **valor real y el valor predicho**.

Ejemplo:

- Valor real: 8
- Predicción: 7.5
- Error: 0.5

## 9.2 Métricas principales

**Error Absoluto (MAE):** Mide el promedio de los errores en valor absoluto. Concretamente, indica en promedio, cuánto se equivoca el modelo.

Ejemplo:

MAE = 0.7 → el modelo se equivoca en promedio 0.7 puntos de nota.

**Error Cuadrático Medio (MSE):** Mide el promedio de los errores al cuadrado. Esto se interpreta como penaliza más los errores grandes. Si un error es muy alto, impacta mucho en esta métrica.

**Raíz del Error Cuadrático Medio (RMSE):** Es la raíz del MSE y se expresa en la misma unidad que la variable (por ejemplo, nota). Es más fácil de interpretar que el MSE.

### 9.3 Caso aplicado: métricas en regresión

Supongamos un modelo que predice notas:

| Estudiante | Real | Predicho |
|------------|------|----------|
| A          | 8    | 7.5      |
| B          | 6    | 6.2      |
| C          | 9    | 8.4      |

**Paso 1:** Se calcula la diferencia entre el valor real y el predicho:

| Estudiante | Error |
|------------|-------|
| A          | 0.5   |
| B          | 0.2   |
| C          | 0.6   |

**Paso 2:** Aplicar las métricas mencionadas en la sección anterior.

**Error Absoluto Medio (MAE):** Se promedian los errores absolutos:

$$MAE = \frac{0.5 + 0.2 + 0.6}{3} = 0.43$$

Esto se interpreta, que en promedio el modelo se equivoca **0.43** en la nota.

**Error Cuadrático Medio (MSE):** Se elevan los errores al cuadrado y se promedian:

$$MSE = \frac{0.25 + 0.04 + 0.36}{3} = 0.216$$

Los errores grandes tienen más peso. En este caso, no hay errores extremos, por lo que el valor es bajo.

**Error Cuadrático Medio (MSE):**

$$RMSE = \sqrt{0.216} \approx 0.46$$

El error promedio es aproximadamente **0.46 puntos, en la misma escala que la nota.**

#### Paso 3: Interpretación global

A partir de las métricas obtenidas, se puede concluir que:

- El modelo comete errores pequeños (menores a 1 punto). Esto se observa en el **MAE = 0.43**, que indica que, en promedio, el error es menor a medio punto.
- Las predicciones son cercanas a los valores reales. Esto se evidencia tanto en el **MAE como en el RMSE ( $\approx 0.46$ )**, que muestran que las diferencias entre valores reales y predichos son bajas.
- No hay errores extremos que afecten significativamente el modelo. Esto se deduce del **MSE bajo (0.216)**, ya que al penalizar los errores grandes, su valor reducido indica que no existen desviaciones importantes.

Por lo tanto, **el modelo puede considerarse adecuado para estimar el rendimiento académico. El modelo no acierta exactamente la nota, pero se equivoca muy poco.** En promedio, la diferencia entre lo real y lo predicho es menor a medio punto."

### 9.4 Revisión y optimización de modelos predictivos

En la práctica profesional, es común que un modelo predictivo **no alcance el nivel de desempeño esperado**. Esto puede deberse a múltiples factores, como problemas en los datos, una mala selección de variables o el uso de técnicas inadecuadas.

Un modelo no confiable no solo pierde valor analítico, sino que puede conducir a **decisiones incorrectas**, con impacto real en organizaciones, personas o procesos.

Por este motivo, cuando un modelo presenta bajo rendimiento, no se descarta automáticamente, sino que se **analiza, ajusta y mejora de manera iterativa**.

Algunos indicadores frecuentes son:

- Baja exactitud en clasificación o errores elevados en regresión
- Resultados inconsistentes o poco estables
- Predicciones que no tienen sentido en el contexto del problema
- Diferencias importantes entre datos reales y predichos
- Desempeño muy bueno en entrenamiento pero malo en nuevos datos

Cuando un modelo predictivo no presenta un desempeño adecuado, en la práctica profesional no se lo descarta inmediatamente, sino que se analiza y mejora de manera iterativa. En primer lugar, es fundamental **revisar la calidad de los datos**, identificando posibles errores, valores faltantes o inconsistencias que puedan afectar los resultados. Luego, se procede a **mejorar la preparación de los datos**, aplicando técnicas de limpieza, transformación o normalización que permitan trabajar con información más adecuada.

Asimismo, resulta necesario **analizar y seleccionar las variables utilizadas**, evaluando si son relevantes para explicar el fenómeno o si faltan variables importantes que puedan mejorar el modelo. En muchos casos, también es conveniente **probar otros modelos o técnicas**, ya que no todos los problemas se resuelven con el mismo enfoque y pequeños cambios pueden generar mejoras significativas. Finalmente, se debe **evaluar nuevamente el modelo**, utilizando las métricas correspondientes, para verificar si los ajustes realizados efectivamente mejoraron su desempeño y determinar si el modelo es confiable para su uso en la toma de decisiones.

En esta unidad se abordaron las principales **técnicas de minería de datos orientadas a la predicción**, comprendiendo la diferencia entre **clasificación y regresión**, así como la importancia de **evaluar e interpretar correctamente los modelos obtenidos**.

A lo largo del recorrido, se destacó que los modelos no solo deben construirse, sino también **analizarse críticamente**, considerando su desempeño, sus limitaciones y su utilidad en contextos reales.

En este sentido, la minería de datos no se limita a generar resultados, sino que implica **transformar datos en información confiable que permita anticipar situaciones y apoyar la toma de decisiones**.