

BANCO DE PREGUNTAS - COLOQUIO FINAL

Procesamiento Digital de Señales de Audio

EJE I: Fundamentos y Procesamiento Digital de la Señal

Pregunta 1: Muestreo y Teorema de Nyquist

P: Explique el teorema de Nyquist-Shannon. Si tiene una señal con frecuencias hasta 4000 Hz, ¿cuál es la frecuencia de muestreo mínima necesaria? ¿Qué ocurre si muestrea a 6000 Hz?

R: El teorema de Nyquist-Shannon establece que para reconstruir fielmente una señal analógica, la frecuencia de muestreo (f_s) debe ser al menos el doble de la frecuencia máxima de la señal (f_{max}): $f_s \geq 2 \times f_{max}$. Para una señal de 4000 Hz, se necesita $f_s \geq 8000$ Hz. Si muestreamos a 6000 Hz, el límite de Nyquist es 3000 Hz, por lo que las frecuencias entre 3000-4000 Hz sufrirán aliasing, apareciendo como frecuencias falsas más bajas y distorsionando irreversiblemente la señal.

Pregunta 2: Cuantización y Resolución

P: Compare la cuantización de 8 bits vs 16 bits. ¿Cuántos niveles tiene cada una? Calcule el SNR teórico para ambas y explique por qué en producción se graba a 24 bits pero se distribuye a 16 bits.

R: 8 bits = 256 niveles, 16 bits = 65,536 niveles. SNR teórico: 8 bits $\approx$ 49.92 dB ($6.02 \times 8 + 1.76$), 16 bits $\approx$ 98.08 dB. Se graba a 24 bits para tener "headroom" durante la producción (mezcla, ecualización, compresión) donde se acumulan errores de redondeo. La reducción a 16 bits se hace al final con dithering, preservando calidad mientras se reduce el tamaño para distribución.

Pregunta 3: Aliasing

P: Describa el fenómeno de aliasing con un ejemplo. Si tiene una señal de 7000 Hz y muestrea a 8000 Hz, ¿qué frecuencia "falsa" aparecerá? ¿Cómo se previene?

R: El aliasing ocurre cuando se muestrea por debajo del límite de Nyquist, haciendo que frecuencias altas se "disfrecen" como bajas. Ejemplo: ruedas de carroza que parecen girar al revés en películas. Con $f_s=8000$ Hz, Nyquist=4000 Hz. Una señal de 7000 Hz aparecerá como: $f_{alias} = |7000 - 8000| = 1000$ Hz. Se previene: (1) aumentando $f_s \geq 2 \times f_{max}$, o (2) aplicando filtro anti-aliasing (pasa-bajos) antes del muestreo.

Pregunta 4: Transformada de Fourier

P: ¿Qué es la Transformada de Fourier y por qué es importante en el procesamiento de audio? Explique la diferencia entre dominio del tiempo y dominio de la frecuencia.

R: La Transformada de Fourier descompone una señal compleja en sus componentes de frecuencia individuales (senoidales simples). Es crucial porque revela información oculta en el dominio del tiempo: qué tonos hay, qué formantes están presentes, qué armónicos existen. Dominio del tiempo: amplitud vs tiempo (¿cuándo suena?). Dominio de la frecuencia: magnitud vs Hz (¿qué frecuencias hay?). Ambos son la misma señal vista desde perspectivas complementarias.

Pregunta 5: Preprocesamiento de Audio

P: Describa el pipeline completo de preprocesamiento: trim, normalización, remuestreo y ajuste de duración. ¿Por qué se aplica en ese orden específico?

R: Pipeline: (1) **Trim**: elimina silencios en bordes usando umbral dB (preserva solo contenido activo). (2) **Normalización**: escala amplitud a $[-1, +1]$ para estandarizar volumen. (3) **Remuestreo**: unifica frecuencia de muestreo (ej: 22050 Hz) para tensores compatibles. (4) **Ajuste de duración**: crop centrado o padding para longitud fija. El orden es crítico: trim primero evita normalizar silencios, normalizar antes de remuestreo optimiza precisión numérica, y el ajuste de duración es el último paso para garantizar tensores de forma fija.

Pregunta 6: Análisis Exploratorio (EDA)

P: ¿Qué es EDA en el contexto de audio? Mencione al menos 4 features que extraería y explique qué información aporta cada una.

R: EDA (Exploratory Data Analysis) es el análisis exploratorio para entender características del dataset antes del modelado. Features clave:

- **RMS Energy**: energía promedio → detecta actividad de voz vs silencio
- **Zero-Crossing Rate**: tasa de cruces por cero → distingue voz "áspera" (ruido) vs "suave" (tono)
- **Spectral Centroid**: centro de gravedad frecuencial → indica "brillo" (agudos vs graves)
- **MFCCs**: coeficientes cepstrales → capturan timbre vocal para reconocimiento de fonemas
- **Spectral Rolloff**: frecuencia donde se acumula 85% de energía → contenido espectral dominante

EJE II: Extracción de Características y Modelado Predictivo

Pregunta 7: Escala Mel

P: ¿Por qué usamos la escala Mel en lugar de Hz directamente? Explique la fórmula $Mel(f) = 2595 \times \log_{10}(1 + f/700)$ y su justificación perceptual.

R: El oído humano NO percibe frecuencias linealmente: es muy sensible a diferencias en graves (100→200 Hz es notable) pero poco en agudos (10000→10100 Hz es casi imperceptible). La fórmula: $f/700$ normaliza respecto a 700 Hz (punto de inflexión), $\log_{10}$ aplica compresión logarítmica (estira graves, comprime agudos), y 2595 es factor de escala. Resultado: 1000 Hz $\approx$ 1000 Mels, pero 10000 Hz $\approx$ 2947 Mels. Esto imita la cóclea humana.

Pregunta 8: MFCCs - Proceso Completo

P: Describa paso a paso cómo se calculan los MFCCs. ¿Por qué se aplica pre-énfasis, ventana de Hamming, FFT, banco de filtros Mel, logaritmo y DCT?

R: Proceso MFCC:

1. **Pre-énfasis:** $y[t] = x[t] - 0.97 \times x[t-1]$ → realza agudos (consonantes /s/, /f/) que tienen menos energía
2. **Framing + Hamming:** divide en ventanas de 25ms con 10ms de solapamiento, suaviza bordes para evitar artefactos
3. **FFT:** transforma cada frame al dominio frecuencial (obtiene espectro)
4. **Banco de filtros Mel:** agrupa frecuencias en bandas triangulares perceptuales (más resolución en graves)
5. **Logaritmo:** comprime rango dinámico (1000:1 → 3:1) y separa fuente (cuerdas) de filtro (tracto vocal)
6. **DCT:** decorrelaciona bandas Mel, comprime información → los primeros 12-13 coeficientes capturan >95% de varianza fonética

Pregunta 9: Delta y Delta-Delta

P: ¿Por qué necesitamos calcular Delta y Delta-Delta además de los MFCCs estáticos? ¿Qué información capturan y cómo se calculan?

R: Los MFCCs estáticos capturan el "estado" del sonido en un instante, pero la voz CAMBIA rápidamente (fonemas duran 50-100ms). **Delta** (primera derivada) mide la VELOCIDAD de cambio: ¿los formantes suben o bajan? Útil para distinguir /a/→/i/

vs /i/→/a/. **Delta-Delta** (segunda derivada) mide la ACELERACIÓN: ¿la velocidad aumenta o disminuye? Detecta transiciones rápidas e inicios/finales de sílabas. Se calculan mediante regresión lineal sobre ventanas de frames adyacentes. Juntos: 13 estáticos + 13 delta + 13 delta-delta = 39 features por frame.

Pregunta 10: Espectrogramas

P: Compare espectrograma lineal vs espectrograma de Mel. ¿Cuándo usaría cada uno? Explique qué representa cada eje y el significado del color.

R: **Espectrograma Lineal:** eje Y en Hz lineal (resolución uniforme), bueno para análisis técnico general, detección de frecuencias específicas. **Espectrograma de Mel:** eje Y en escala Mel (más bandas en graves, menos en agudos), ideal para voz porque imita percepción humana, mejor separación de formantes F1/F2. Ambos: eje X = tiempo, eje Y = frecuencia, color = intensidad en dB (azul=bajo, rojo=alto). Mel comprime >3000 Hz (ruido irrelevante) y expande 0-1000 Hz (formantes vocales).

Pregunta 11: Validación Cruzada

P: Explique qué es validación cruzada (cross-validation) y por qué es importante. ¿Qué es k-fold CV y por qué usamos stratified split en datasets desbalanceados?

R: Validación cruzada evalúa la capacidad de generalización del modelo, no solo su desempeño en un split específico. **K-fold CV:** divide datos en k particiones, entrena k veces usando k-1 para train y 1 para test, promedia las métricas. Reduce varianza de la estimación. **Stratified split:** mantiene proporción de clases en train y test. Crítico en datasets desbalanceados (ej: 90% sana, 10% patológica) → sin stratification, el test podría no tener muestras de la clase minoritaria, dando métricas engañosas.

Pregunta 12: Métricas de Clasificación

P: Defina accuracy, precision, recall y F1-score. En un sistema de detección de disartria en ELA, ¿qué métrica priorizaría y por qué?

R:

- **Accuracy:** $(VP+VN)/total \rightarrow$ % total de aciertos
- **Precision:** $VP/(VP+FP) \rightarrow$ de los que dije "positivo", ¿cuántos realmente lo son?
- **Recall:** $VP/(VP+FN) \rightarrow$ de los positivos reales, ¿cuántos detecté?
- **F1-score:** media armónica de precision y recall $\rightarrow$ balancea ambas

En ELA, priorizaría **RECALL** de la clase "disartrica". Un falso negativo (decir "sana" cuando hay disartria) retrasa el acceso a terapia y sistemas AAC, afectando calidad de vida. Un falso positivo (decir "disartrica" cuando es sana) genera ansiedad pero permite evaluación fonoaudiológica de confirmación. Mejor pecar por exceso de alerta en contexto clínico.

Pregunta 13: Random Forest vs SVM

P: Compare Random Forest y SVM para clasificación de audio. ¿Cuándo usaría cada uno? Explique ventajas y desventajas de cada algoritmo.

R: Random Forest: ensemble de árboles de decisión. Ventajas: maneja features no escaladas, robusto a outliers, proporciona feature importance, menos propenso a overfitting con muchos árboles. Desventajas: más lento en inferencia, menos interpretable, puede overfittear con ruido. **SVM:** encuentra hiperplano óptimo de separación. Ventajas: efectivo en espacios de alta dimensión (como features de audio), funciona bien con pocos datos, kernel trick permite fronteras no lineales. Desventajas: requiere escalado de features, lento en datasets grandes, difícil de interpretar, sensible a hiperparámetros (C, gamma). Para audio con 86 features y dataset mediano (~1000 muestras), SVM con kernel RBF suele funcionar mejor. Para datasets grandes o features heterogéneas, Random Forest es más robusto.

Pregunta 14: Feature Importance

P: ¿Qué es feature importance y por qué es importante? En un modelo de Random Forest para detectar disartria, ¿qué features esperaría que fueran más importantes y por qué?

R: Feature importance mide cuánto contribuye cada característica a las decisiones del modelo. Importante para: (1) interpretabilidad clínica (¿qué parámetros acústicos reflejan síntomas?), (2) reducir dimensionalidad (eliminar features redundantes), (3) validar que el modelo usa señales fisiológicamente relevantes, no artefactos. En disartria ELA, esperaría que **spectral tilt** (pérdida de agudos por pobre cierre glótico), **ZCR** (ruido por imprecisión articulatoria), **MFCC 1-3** (configuración del tracto vocal alterada), y **energía RMS** (debilidad muscular) fueran las más importantes, ya que correlacionan con síntomas bulbares documentados en literatura clínica.

Pregunta 15: Overfitting y Regularización

P: Explique qué es overfitting y cómo se detecta. Mencione al menos 3 técnicas de regularización y cómo funcionan.

R: Overfitting: el modelo "memoriza" los datos de entrenamiento (incluyendo ruido) en lugar de aprender patrones generalizables. Se detecta cuando: accuracy en train es muy alta (>95%) pero en test/validación es baja (<70%), o cuando la brecha train-test es grande. **Técnicas de regularización:**

1. **Dropout** (en redes neuronales): desactiva neuronas aleatoriamente durante training → previene co-adaptación excesiva
2. **L1/L2 regularization:** agrega penalización a la función de pérdida basada en magnitud de pesos → evita pesos extremos
3. **Early stopping:** detiene training cuando validación deja de mejorar → previene sobreajuste progresivo
4. **Max depth** (en árboles): limita profundidad → evita divisiones demasiado específicas
5. **Data augmentation:** aumenta dataset con variaciones (ruido, pitch shift) → expone modelo a más variabilidad

EJE III: Desarrollo de Sistemas de IA y Aplicaciones Avanzadas

Pregunta 16: ASR - Reconocimiento Automático del Habla

P: Describa la arquitectura de Whisper (OpenAI). ¿Qué es un encoder-decoder transformer? ¿Por qué Whisper es multilingüe y multitarea?

R: Whisper es un transformer encoder-decoder entrenado en 680k horas de audio multilingüe con transcripciones. **Encoder:** procesa el audio (mel-spectrogram) y genera representaciones contextuales. **Decoder:** genera texto token por token de forma autoregresiva condicionado al encoder. Es **multilingüe** porque se entrenó con audio en 99 idiomas, aprendiendo un espacio latente compartido donde diferentes idiomas se alinean. Es **multitarea** porque se entrenó con tareas variadas (transcripción, traducción, detección de idioma) especificadas mediante tokens de prompt especiales. No necesita fine-tuning por tarea; el mismo modelo hace todo según el prompt.

Pregunta 17: TTS - Síntesis de Voz

P: Compare TTS concatenativo, paramétrico y neuronal. Explique cómo funciona FastSpeech2 y qué ventajas tiene sobre WaveNet o Tacotron.

R: Concatenativo: une fragmentos de voz grabada → natural pero requiere base de datos enorme, inflexible. **Paramétrico:** usa modelos estadísticos (HMM) → flexible pero voz robótica. **Neuronal:** redes profundas → mejor calidad y control. **FastSpeech2** es no-autoregresivo: (1) extrae features lingüísticas del texto, (2)

predice duración fonética explícitamente, (3) genera mel-spectrogram en paralelo (no frame por frame), (4) vocoder (HiFi-GAN) convierte a audio. Ventajas sobre **WaveNet/Tacotron** (autoregresivos): 10-50× más rápido (paralelo), más estable (sin errores acumulativos), control prosódico explícito (duración, pitch, energía predecibles).

Pregunta 18: Fine-Tuning y Transfer Learning

P: ¿Qué es fine-tuning y por qué es más eficiente que entrenar desde cero? Explique LoRA (Low-Rank Adaptation) y cuándo lo usaría.

R: Fine-tuning: toma un modelo preentrenado (ej: Whisper en 680k horas) y lo adapta a un dominio específico (ej: voz médica) con pocos datos. Más eficiente porque: (1) el modelo ya aprendió representaciones generales del habla, (2) requiere menos datos (cientos vs miles de horas), (3) converge más rápido, (4) mejor generalización. **LoRA:** inyecta matrices de bajo rango (rank $r=8-16$) en capas de atención/FFN, entrenando SOLO esas matrices (1-5% de parámetros) mientras congela el backbone. Ventajas: (1) muy eficiente en memoria, (2) evita catastrophic forgetting, (3) permite tener múltiples adapters para diferentes dominios sin duplicar el modelo base. Se usa cuando: datos limitados, recursos computacionales restringidos, o se necesita adaptar a múltiples dominios.

Pregunta 19: Tokenización de Audio

P: ¿Qué es tokenización de audio y por qué es necesaria para LLMs de voz? Compare tokens discretos (EnCodec) vs embeddings continuos (wav2vec 2.0).

R: Tokenización de audio convierte la señal continua en unidades discretas que un LLM puede procesar. Necesaria porque LLMs trabajan con secuencias de tokens, no con ondas continuas. **Tokens discretos** (EnCodec, SoundStream): comprimen audio a secuencias de índices enteros (como palabras en texto). Ventajas: secuencias más cortas, compatible con arquitecturas de lenguaje existentes, eficiente en memoria. Desventajas: pérdida de información, artefactos de compresión. **Embeddings continuos** (wav2vec 2.0, HuBERT): representan audio como vectores densos en espacio latente. Ventajas: más información preservada, representaciones ricas. Desventajas: secuencias más largas, requiere adapters para mapear a espacio de LLM, más costo computacional. En la práctica, sistemas como VALL-E usan tokens discretos; Whisper usa embeddings continuos del encoder.

Pregunta 20: Modelos Autoregresivos vs No Autoregresivos

P: Explique la diferencia entre modelos autoregresivos y no autoregresivos en ASR/TTS. ¿Cuáles son las ventajas y desventajas de cada enfoque?

R: Autoregresivo (Tacotron, WaveNet, GPT): genera output secuencialmente, un token/frame a la vez, donde cada paso depende de los anteriores. Ventajas: mayor calidad (captura dependencias de largo alcance), más estable, maduro. Desventajas: LENTO (no paralelizable), latencia alta, propenso a errores acumulativos (un error se propaga). **No autoregresivo** (FastSpeech, Parallel WaveGAN): genera todo el output en paralelo. Ventajas: 10-100× más rápido, latencia baja, ideal para tiempo real. Desventajas: calidad ligeramente inferior (pierde dependencias temporales), más difícil de entrenar (requiere alineación explícita), menos maduro. En producción: ASR suele ser autoregresivo (calidad > velocidad); TTS tiende a no-autoregresivo (latencia crítica para asistentes de voz).

Pregunta 21: Despliegue y Optimización

P: Mencione al menos 3 técnicas para optimizar modelos de audio para despliegue en producción. Explique cuantización, pruning y exportación a ONNX/TensorRT.

R: Técnicas de optimización:

1. **Cuantización:** reduce precisión numérica (float32 → int8/int4). Reduce tamaño 4× y acelera inferencia 2-4×. Tipos: post-training (rápida, ligera pérdida) vs quantization-aware training (mejor calidad, más costosa).
2. **Pruning:** elimina pesos/neuronas menos importantes (cerca de cero). Reduce tamaño y operaciones. Estructural (elimina filtros completos, acelera hardware) vs no estructural (sparsity, requiere hardware especializado).
3. **ONNX/TensorRT:** exporta modelo a formato optimizado para inferencia. ONNX: formato interoperable entre frameworks. TensorRT: optimizaciones específicas para GPU NVIDIA (kernel fusion, precision mixta). Acelera 2-10×.
4. **Knowledge distillation:** entrena modelo pequeño (student) para imitar modelo grande (teacher). Mantiene calidad con menos parámetros.

Pregunta 22: Streaming y Latencia

P: ¿Qué desafíos presenta el ASR en tiempo real (streaming)? Explique chunking, cache KV y speculative decoding.

R: Desafíos del streaming: (1) latencia baja requerida (<500ms), (2) memoria limitada (no se puede procesar audio infinito), (3) decisiones parciales pueden cambiar (revisión de hipótesis). **Técnicas:**

- **Chunking**: divide audio en ventanas de 30s con solapamiento. Procesa cada chunk independientemente. Reduce memoria pero puede perder contexto entre chunks.
- **Cache KV**: en transformers, almacena key-value de attention de frames anteriores. Evita recalcular attention completo en cada paso → acelera inferencia incremental.
- **Speculative decoding**: modelo pequeño genera borrador rápido, modelo grande lo corrige. Combina velocidad de modelo pequeño con calidad de modelo grande.
- **Triggerless streaming**: decide automáticamente cuándo emitir tokens basándose en confianza, sin esperar fin de utterance.

Pregunta 23: Ética y Sesgos en ASR/TTS

P: Discuta los principales desafíos éticos en sistemas de voz: sesgos, privacidad y deepfakes. ¿Cómo mitigaría cada uno?

R: **Sesgos**: modelos entrenados en datos desbalanceados fallan en acentos minoritarios, dialectos, voces femeninas/infantiles, patologías del habla. Mitigación: (1) datasets diversos y representativos, (2) evaluación por subpoblación (no solo accuracy global), (3) fine-tuning en dominios subrepresentados, (4) auditorías de fairness. **Privacidad**: la voz es biométrica única. Riesgos: identificación no consentida, vigilancia. Mitigación: (1) procesamiento on-device (sin enviar a nube), (2) federated learning (entrenar sin centralizar datos), (3) differential privacy (agregar ruido a gradients), (4) consentimiento informado explícito. **Deepfakes/TTS malicioso**: clonación de voz para fraude, desinformación. Mitigación: (1) watermarks en audio sintético, (2) detectores de deepfake, (3) regulación legal, (4) verificación multifactor en sistemas sensibles.

Pregunta 24: Evaluación de Modelos de Voz

P: ¿Qué métricas usaría para evaluar un sistema ASR? ¿Y un sistema TTS? Explique WER, CER, MOS y SIM-O.

R: ASR:

- **WER (Word Error Rate)**: (Sustituciones + Inserciones + Eliminaciones) / total palabras. Estándar industrial. <10% excelente, <20% bueno.
- **CER (Character Error Rate)**: similar pero a nivel de caracteres. Mejor para idiomas sin espacios o con morfología compleja.
- **Real-time factor**: tiempo de inferencia / duración de audio. <1 es tiempo real.

TTS:

- **MOS (Mean Opinion Score)**: evaluación subjetiva de naturalidad (1-5, 5=humano). Requiere oyentes humanos. >4.0 excelente.
- **SIM-O**: similitud de hablante entre voz sintetizada y referencia. Mide calidad de clonación.
- **MCD (Mel Cepstral Distortion)**: distancia espectral entre audio real y sintetizado. Métrica objetiva.

Pregunta 25: Arquitecturas Multimodales

P: ¿Qué es un modelo multimodal de voz? Describa cómo SpeechGPT o Voicebox integran audio, texto y conocimiento. ¿Qué ventajas tiene?

R: Modelo multimodal procesa y genera múltiples modalidades (audio, texto, visión) en un espacio latente unificado. **SpeechGPT**: (1) entrena ASR para transcribir audio a texto, (2) usa LLM (texto) para razonamiento/compreensión, (3) entrena TTS para generar audio desde texto. Pipeline: audio → texto → razonamiento → texto → audio. **Voicebox**: modelo generativo no-autoregresivo que puede hacer ASR, TTS, traducción, edición de audio con el mismo modelo. Entrenado con "infilling" (rellenar audio enmascarado condicionado a texto). **Ventajas**: (1) razonamiento semántico profundo (no solo transcripción), (2) zero-shot a nuevas tareas, (3) contexto cruzado (audio+texto+imágenes), (4) agentes de voz autónomos que pueden "pensar" antes de hablar.

Preguntas Integradoras (Conexión entre Ejes)

Pregunta 26: De MFCCs a Transformers

P: Compare la extracción manual de features (MFCCs) con el aprendizaje de representaciones autosupervisadas (wav2vec 2.0). ¿Por qué hubo un cambio de paradigma? ¿Cuándo usaría cada enfoque?

R: MFCCs (handcrafted): features diseñadas manualmente basadas en conocimiento de DSP y percepción auditiva. Ventajas: interpretables, requieren pocos datos, funcionan bien en tareas específicas con datasets pequeños. Desventajas: pierden información, no capturan contexto, dependen de supuestos que pueden no ser óptimos. **wav2vec 2.0 (autosupervisado)**: transformer entrena en miles de horas sin etiquetar, aprendiendo representaciones contextuales ricas. El modelo descubre automáticamente qué features son útiles. Ventajas: capturan contexto de largo alcance, mejoran con más datos, state-of-the-art en la mayoría de tareas. Desventajas: requieren muchos datos/computación, "caja negra" (poco interpretables), overkill para tareas simples. **Cambio de paradigma**: antes, el cuello

de botella era "¿qué features extraigo?"; ahora es "¿cómo entreno/ajusto el modelo?". **Cuándo usar:** MFCCs para datasets pequeños (<1000 muestras), recursos limitados, o cuando se necesita interpretabilidad clínica. wav2vec para datasets grandes, aplicaciones de producción, o cuando se busca máxima accuracy.

Pregunta 27: Pipeline Completo

P: Describa un pipeline completo desde la grabación de audio hasta la predicción de un clasificador de comandos de voz. Incluya preprocesamiento, extracción de features, modelado y post-procesamiento.

R: Pipeline completo:

1. **Adquisición:** grabación a 16-44kHz, formato WAV/FLAC (sin compresión con pérdida).
2. **Preprocesamiento (Eje I):**
 - Trim: eliminar silencios en bordes (top_db=30-40)
 - Normalización: escalar a [-1,+1]
 - Remuestreo: unificar a 16kHz o 22050Hz
 - Ajuste de duración: crop/pad a longitud fija (ej: 1.0s)
3. **Extracción de features (Eje II):**
 - MFCCs: 13 coeficientes + deltas + delta-deltas = 39 features/frame
 - Features espectrales: centroid, rolloff, ZCR, RMS
 - Agregación temporal: mean + std → vector fijo de ~86 dimensiones
4. **Modelado (Eje II):**
 - Escalado: StandardScaler (resta media, divide std)
 - Entrenamiento: Random Forest o SVM con validación cruzada
 - Evaluación: accuracy, precision, recall, F1, matriz de confusión
5. **Post-procesamiento:**
 - Umbral de confianza: rechazar predicciones con probabilidad <0.7
 - Votación por mayoría: si se graban múltiples utterances, votar
 - Smooth temporal: en streaming, suavizar predicciones consecutivas
6. **Despliegue (Eje III):**

- Exportar a ONNX/TFLite para inferencia eficiente
- API REST o interfaz web (Gradio/Streamlit)
- Monitoreo de drift: detectar si distribución de datos cambia en producción

Pregunta 28: Adaptación a Dominio Específico

P: Tiene un modelo ASR general (Whisper) que funciona bien en voz clara pero mal en voz de pacientes con ELA. Proponga una estrategia de adaptación de dominio. Justifique cada decisión.

R: Estrategia de adaptación:

1. **Recolección de datos:** grabar 50-100 horas de voz de pacientes con ELA (consentimiento informado, anonimización). Diversidad: severidad leve/moderada/severa, diferentes hablantes, condiciones de grabación variadas.
2. **Fine-tuning vs LoRA:** usar **LoRA** (no fine-tuning completo) porque: (1) datos limitados (riesgo de overfitting), (2) preservar conocimiento general del modelo base, (3) eficiencia computacional, (4) posibilidad de tener múltiples adapters (ELA, Parkinson, ictus).
3. **Data augmentation:** aplicar ruido, reverb, pitch shift, time stretch a los datos de ELA para aumentar variabilidad y robustez.
4. **Evaluación específica:** no usar WER global; evaluar separadamente por severidad, por hablante, por tipo de fonema (vocales vs consonantes fricativas).
5. **Métricas clínicas:** además de WER, medir inteligibilidad percibida (MOS), tiempo de latencia (crítico para AAC), tasa de errores críticos (palabras médicas mal transcritas).
6. **Validación clínica:** prueba con fonoaudiólogos y pacientes reales, no solo métricas automáticas.
7. **Despliegue ético:** procesamiento on-device (privacidad), opción de desactivar logging, consentimiento explícito para mejora del modelo.

Pregunta 29: Comparación de Enfoques

P: Compare tres enfoques para clasificar voz patológica: (1) MFCCs + Random Forest, (2) Espectrogramas + CNN, (3) Whisper fine-tuned. Discuta ventajas, desventajas y cuándo usaría cada uno.

R: Enfoque 1: MFCCs + Random Forest

- Ventajas: interpretable (feature importance), rápido en train/inferencia, funciona con pocos datos (~100 muestras), requiere CPU.
- Desventajas: pierde información temporal/espectral, accuracy limitada (~75-85%), features handcrafted pueden no ser óptimas.
- Cuándo usar: recursos limitados, necesidad de interpretabilidad clínica, dataset pequeño, prototipado rápido.

Enfoque 2: Espectrogramas + CNN

- Ventajas: captura patrones espaciotemporales, mejor accuracy (~85-92%), automático (sin feature engineering), visualmente interpretable (activaciones).
- Desventajas: requiere más datos (~1000 muestras), GPU para entrenamiento, más lento que RF, menos interpretable que features manuales.
- Cuándo usar: dataset mediano, se busca mejor accuracy, se tiene GPU, se quiere balance entre rendimiento e interpretabilidad.

Enfoque 3: Whisper fine-tuned

- Ventajas: state-of-the-art accuracy (>92%), captura contexto semántico, robusto a ruido/variabilidad, zero-shot a tareas relacionadas.
- Desventajas: requiere muchos datos (~100+ horas) o LoRA, GPU obligatoria, lento en inferencia, "caja negra", overkill para tareas simples.
- Cuándo usar: dataset grande, máxima accuracy requerida, recursos computacionales disponibles, aplicación de producción crítica.

Recomendación práctica: empezar con MFCCs+RF para baseline rápido, luego probar CNN si se necesita más accuracy, finalmente Whisper si se tienen datos y recursos suficientes.

Pregunta 30: Reflexión Crítica y Futuro

P: Reflexione sobre el futuro del procesamiento de voz con LLMs. ¿Eliminan los transformers la necesidad de DSP clásico (MFCCs, STFT)? ¿Qué habilidades debe tener un profesional en 2026?

R: Los transformers **NO** eliminan el DSP clásico, lo transforman:

- **DSP sigue siendo necesario** para: (1) preprocesamiento (trim, normalización, remuestreo), (2) entendimiento de qué hacen los modelos

(STFT dentro de transformers), (3) debugging (visualizar espectros cuando el modelo falla), (4) aplicaciones embebidas/recursos limitados donde no cabe un transformer, (5) interpretabilidad clínica (explicar por qué el modelo tomó una decisión).

- **DSP evoluciona:** antes "¿qué features extraigo?", ahora "¿cómo preparo datos para el modelo?" y "¿cómo interpreto lo que el modelo aprendió?".

Habilidades del profesional en 2026:

1. **Fundamentos sólidos:** DSP, teoría de señales, ML clásico (no solo "import transformers")
2. **Arquitecturas modernas:** transformers, fine-tuning, LoRA, RAG
3. **Ingeniería de datos:** limpieza, augmentación, versionado de datasets
4. **Despliegue:** optimización (cuantización, ONNX), monitoreo, MLOps
5. **Ética y regulación:** sesgos, privacidad, GDPR/HIPAA, consentimiento informado
6. **Dominio específico:** si trabaja en salud, entender fisiología vocal; si es legal, fonética forense
7. **Comunicación:** explicar modelos complejos a no-técnicos, documentar decisiones

Conclusión: El futuro no es "DSP vs transformers", sino **DSP + transformers + dominio + ética**. El profesional debe ser puente entre teoría, tecnología y aplicación real.