

TECNICATURA SUPERIOR EN

**Ciencia de Datos e
Inteligencia Artificial**

TÉCNICAS DE PROCESAMIENTO DEL HABLA

EJE N°1: Fundamentos y Procesamiento Digital de la Señal

**Tema: Análisis Exploratorio de Datos
(EDA)**

EJE I: FUNDAMENTOS Y PROCESAMIENTO DIGITAL DE LA SEÑAL

Tema 3: Análisis Exploratorio de Audio (EDA) con Transformada de Fourier

Identificación de variables y aplicación de la Transformada de Fourier para el tratamiento de datos

OBJETIVOS DE APRENDIZAJE

Al finalizar este módulo, podrás:


- Comprender el propósito del Análisis Exploratorio de Datos (EDA) aplicado a audio
- Identificar y clasificar las principales variables/features de una señal de audio
- Entender conceptualmente la Transformada de Fourier y su importancia
- Aplicar la FFT (Fast Fourier Transform) para analizar contenido frecuencial
- Interpretar espectrogramas y representaciones tiempo-frecuencia
- Extraer conclusiones estadísticas de datasets de audio
- Detectar patrones, anomalías y relaciones entre variables acústicas

CONTENIDO INTERACTIVO

SECCIÓN 1: ¿QUÉ ES EDA EN AUDIO?

1.1 El Propósito del Análisis Exploratorio

Concepto intuitivo: El EDA (Exploratory Data Analysis) es como ser un "detective de datos": antes de construir modelos complejos, necesitas **conocer** tus datos, entender sus características, detectar problemas y descubrir patrones ocultos.



Flujo del EDA en audio:

- Entrada: Dataset de audios procesados
- Proceso: Extracción de features → Visualización → Estadísticos → Insights
- Salida: Comprensión del dataset, detección de anomalías, hipótesis

Preguntas clave del EDA:

1. **Distribución:** ¿Cómo se comportan las variables? (¿normales, sesgadas?)
2. **Relaciones:** ¿Qué features están correlacionadas?
3. **Anomalías:** ¿Hay valores atípicos o errores?
4. **Diferencias:** ¿Se distinguen las clases/categorías entre sí?
5. **Calidad:** ¿Hay datos faltantes o inconsistentes?

1.2 Diferencia entre EDA y Modelado

EDA	Modelado
Explorar y entender	Predecir y clasificar
Descriptivo	Predictivo
Sin supervisión	Con/sin supervisión
Visualizaciones, estadísticos	Algoritmos, métricas
PRIMERO	DESPUÉS

Regla de oro: *Nunca saltes el EDA.* Un buen análisis exploratorio te ahorra horas de debugging después.

SECCIÓN 2: VARIABLES Y FEATURES DE AUDIO

2.1 Clasificación de Variables

Variables temporales (dominio del tiempo):

Feature	Qué mide	Unidad	Rango típico
Duración	Longitud temporal	segundos (s)	0.1 - 600 s
RMS Energy	Energía promedio	adimensional	0.0 - 1.0
Zero-Crossing Rate	Cambios de signo	proporción	0.0 - 1.0
Amplitud máxima	Pico de señal	adimensional	-1.0 a +1.0
Factor de cresta	Relación pico/RMS	adimensional	1.0 - 10.0+

Variables espectrales (dominio de la frecuencia):

Feature	Qué mide	Interpretación
Spectral Centroid	"Centro de gravedad" frecuencial	Sonidos "brillantes" vs "oscuros"
Spectral Bandwidth	Ancho de banda espectral	Rango de frecuencias activas
Spectral Rolloff	Frecuencia de corte (85% energía)	Dónde se concentra la energía
Spectral Flatness	Uniformidad del espectro	Ruido (alto) vs tono (bajo)
MFCCs	Coeficientes cepstrales	Timbre y características vocales

Variables estadísticas derivadas:

Para cada feature, calculamos:

- **Media:** valor central
- **Desviación estándar:** variabilidad
- **Mín/Máx:** rango
- **Percentiles:** distribución (25%, 50%, 75%)

2.2 Ejemplo: Dataset de Comandos de Voz

Audio features table concept

duration	rms_mean	zcr_mean	centroid_mean	rolloff_mean	label
	161.12	23.34	93.71	31.76	grave
	116.74	42.04	23.89	37.38	agudo
	112.96	77.69	16.38	33.48	agudo
	146.37	22.83	18.63	73.95	agudo
	118.36	23.39	10.38	35.56	agudo
	123.36	62.56	34.45	32.38	agudo
	117.33	61.12	32.64	20.69	agudo

■ grave ■ medio
■ medio ■ agudo

Tabla conceptual de features extraídas:

- Columnas: duration, rms_mean, zcr_mean, centroid_mean, rolloff_mean, label
- Filas: múltiples muestras de audio
- Colores diferenciando clases (ej. "sí", "no", "izquierda", "derecha")


SECCIÓN 3: TRANSFORMADA DE FOURIER - CONCEPTO INTUITIVO

3.1 La Idea Fundamental

Analogía musical: Imagina un acorde de piano. Tu oído escucha **un solo sonido complejo**, pero en realidad es la **suma de varias notas individuales** (frecuencias) sonando juntas.

La Transformada de Fourier hace exactamente eso:

- **Entrada:** Señal compleja en el tiempo (¿qué suena?)
- **Salida:** Lista de frecuencias individuales (¿qué notas hay?)



Descomposición de Fourier visual:

- Arriba: señal compleja (suma de 3 senoidales)
- Centro: fórmula conceptual "Señal(t) = $f_1 + f_2 + f_3$ "
- Abajo: espectro mostrando 3 picos en las frecuencias correspondientes

3.2 ¿Por qué es Importante?

Problema del dominio del tiempo: En el waveform, todas las frecuencias están **mezcladas**. No puedes distinguir fácilmente:

- Si hay un tono de 440 Hz o 880 Hz
- Si el sonido es "grave" o "agudo"

- Qué armónicos están presentes

Solución del dominio de la frecuencia: La FFT **separa** las frecuencias, permitiéndote: ✓ Identificar notas musicales

✓ Detectar formantes en voz

✓ Filtrar ruido específico

✓ Clasificar sonidos por su contenido espectral

3.3 La Fórmula (Solo para Referencia)

⚠ **No necesitas memorizarla.** Entiende el concepto:

$$X(f) = \int x(t) \cdot e^{(-j2\pi ft)} dt$$

Donde:

- $x(t)$: señal en el tiempo
- $X(f)$: representación en frecuencia
- f : frecuencia
- j : unidad imaginaria ($\sqrt{-1}$)


Lo importante:

- La integral "suma" la señal multiplicada por ondas complejas
- Cada frecuencia f produce un valor que indica "cuánto hay de esa frecuencia"
- El resultado es un **espectro**: magnitud vs frecuencia

SECCIÓN 4: FFT EN LA PRÁCTICA

4.1 Fast Fourier Transform (FFT)

¿Qué es FFT? Es un **algoritmo eficiente** para calcular la Transformada de Fourier. En lugar de tomar horas, lo hace en milisegundos.



Comparación visual:

- Izquierda: waveform de 1 segundo de audio
- Derecha: espectro de frecuencias (FFT) mostrando picos en 300 Hz y 800 Hz
- Flecha indicando "Transformación"

4.2 Parámetros Clave de la FFT

1. Tamaño de ventana (n_fft):

- Número de muestras a analizar simultáneamente
- Típico: 2048, 4096, 8192 (potencias de 2)
- **Más grande** → mejor resolución en frecuencia, peor en tiempo
- **Más pequeño** → mejor resolución en tiempo, peor en frecuencia

2. Frecuencia de muestreo (sr):

- Determina el **rango máximo** de frecuencias analizables
- Límite de Nyquist: $f_{\text{max}} = sr / 2$
- Ejemplo: $sr=22050 \text{ Hz} \rightarrow f_{\text{max}}=11025 \text{ Hz}$

3. Ventana (window):

- Función que suaviza los bordes de cada segmento
- Típica: Hann, Hamming, Blackman
- Evita "artefactos" en los bordes


4.3 Interpretando el Resultado

Estructura del espectro:

python

```
# Ejemplo conceptual
fft_result = np.fft.fft(señal)
frecuencias = np.fft.fftfreq(len(señal), d=1/sr)

# Resultado:
# - frecuencias: array [0, 10, 20, ..., 11025] Hz
# - fft_result: magnitud compleja para cada frecuencia
# - |fft_result|: magnitud absoluta (lo que graficamos)
```



Espectro etiquetado:


- Eje X: Frecuencia (Hz) de 0 a 11025
- Eje Y: Magnitud (dB)
- Picos marcados: "Frecuencia fundamental", "Armónicos"
- Zonas sombreadas: "Rango de voz", "Ruido"

SECCIÓN 5: ESPECTROGRAMAS AVANZADOS

5.1 ¿Qué es un Espectrograma?

Definición: Un espectrograma es una **secuencia de FFTs** a lo largo del tiempo. Muestra:

- **Eje X:** Tiempo
- **Eje Y:** Frecuencia
- **Color:** Intensidad (magnitud) de cada frecuencia en cada momento



Espectrograma detallado:


- Palabra "hola" pronunciada
- Formantes visibles como bandas horizontales brillantes
- Ejes claramente etiquetados
- Barra de color indicando dB

5.2 STFT: Short-Time Fourier Transform

Problema: La FFT tradicional asume que la señal es **estacionaria** (no cambia con el tiempo). ¡Pero la voz y la música cambian constantemente!

Solución: STFT

1. Dividir la señal en **ventanas cortas** (ej. 20-40 ms)
2. Aplicar FFT a cada ventana
3. Apilar los resultados en una matriz tiempo-frecuencia



Proceso STFT visual:

- Señal larga en el tiempo
- Ventanas deslizantes superpuestas (marcadas en colores)
- Cada ventana → una columna del espectrograma
- Resultado: matriz 2D tiempo×frecuencia

5.3 Parámetros del Espectrograma

Parámetro	Efecto	Valor típico
n_fft	Resolución frecuencial	2048-4096
hop_length	Superposición entre ventanas	$n_fft/4$ o $n_fft/2$
win_length	Tamaño de ventana	Igual a n_fft
window	Función de suavizado	'hann'

Compromiso tiempo-frecuencia:

- **Ventana larga:** Buena resolución en frecuencia, mala en tiempo
- **Ventana corta:** Buena resolución en tiempo, mala en frecuencia

Analogía: Es como tomar fotos:

- Tiempo de exposición largo → imagen nítida pero pierdes movimiento
- Tiempo de exposición corto → congelas el movimiento pero menos detalle


SECCIÓN 6: ANÁLISIS ESTADÍSTICO DE FEATURES

6.1 Estadísticos Descriptivos

Para cada feature extraída, calcula:

Estadístico	Fórmula	Qué te dice
Media	$\mu = \sum x/n$	Valor central típico
Mediana	Valor del medio	Resistente a outliers
Desviación estándar	$\sigma = \sqrt{(\sum (x-\mu)^2/n)}$	Variabilidad/dispersión
Mínimo/Máximo	min(x), max(x)	Rango extremo
Percentiles	P25, P50, P75	Distribución completa
Skewness	Asimetría	¿Sesgo a izquierda/derecha?
Kurtosis	"Achatamiento"	¿Colas pesadas o ligeras?

6.2 Visualizaciones Estadísticas



Dashboard de EDA:

- Panel 1: Histograma de RMS Energy con curva normal superpuesta
- Panel 2: Boxplot comparando centroid por clase

- Panel 3: Matriz de correlación (heatmap)
- Panel 4: Scatter plot de 2 features con clases coloreadas

Tipos de gráficos para EDA:

1. **Histograma:** Distribución de una variable
2. **Boxplot:** Comparación de distribuciones entre clases
3. **Violin plot:** Distribución + densidad
4. **Scatter plot:** Relación entre 2 variables
5. **Heatmap de correlación:** Relaciones multivariadas
6. **Pairplot:** Todas las combinaciones de features

6.3 Detección de Anomalías

Métodos simples:

1. Regla 3-sigma:


python

```
# Valores fuera de  $\mu \pm 3\sigma$  son sospechosos
limite_inf = media - 3*desviacion
limite_sup = media + 3*desviacion
anomalias = datos[(datos < limite_inf) | (datos > limite_sup)]
```

2. Rango intercuartílico (IQR):

python

```
Q1 = percentil_25
Q3 = percentil_75
IQR = Q3 - Q1
limite_inf = Q1 - 1.5*IQR
limite_sup = Q3 + 1.5*IQR
```




Detección de outliers:

- Boxplot con puntos rojos marcando valores atípicos
- Líneas punteadas mostrando límites IQR
- Anotación: "¿Errores de grabación o eventos raros?"

SECCIÓN 7: VISUALIZACIÓN PARA EDA

7.1 Waveform Comparativo

Objetivo: Ver diferencias visuales entre clases.




Comparación de waveforms:

- 4 filas: diferentes comandos de voz ("sí", "no", "izquierda", "derecha")
- Misma escala de tiempo y amplitud
- Patrones distintivos visibles

7.2 Espectrogramas por Clase

Objetivo: Identificar patrones espectrales característicos.




Grid de espectrogramas:

- 2×2 grid mostrando 4 clases diferentes
- Mismos parámetros de STFT
- Diferencias en formantes y energía visibles

7.3 Proyecciones Dimensionales

PCA (Principal Component Analysis): Reduce múltiples features a 2-3 dimensiones para visualización.



Scatter plot PCA:


- Eje X: PC1 (40% varianza)
- Eje Y: PC2 (25% varianza)
- Puntos coloreados por clase
- Elipses mostrando concentración por categoría

SECCIÓN 8: DETECCIÓN DE PATRONES Y RELACIONES

8.1 Matriz de Correlación

Qué mide: La correlación indica si dos variables se mueven juntas:

- **+1:** Correlación perfecta positiva
- **0:** Sin correlación
- **-1:** Correlación perfecta negativa



Heatmap de correlación:

- Features en ambos ejes
- Colores: rojo (positivo), azul (negativo), blanco (cero)
- Valores numéricos en celdas
- Features redundantes identificadas


Interpretación:

- **Alta correlación** (>0.8): Features redundantes, considera eliminar una
- **Baja correlación** con target: Feature poco útil para clasificación
- **Correlación negativa:** Relación inversa

8.2 Análisis por Clases

Comparación estadística:

Feature	Clase A (media $\pm\sigma$)	Clase B (media $\pm\sigma$)	Diferencia
RMS	0.25 $\pm$ 0.05	0.18 $\pm$ 0.04	✓ Significativa
Centroid	1200 $\pm$ 300 Hz	1150 $\pm$ 320 Hz	✗ Similar
ZCR	0.08 $\pm$ 0.02	0.15 $\pm$ 0.03	✓ Muy diferente



Boxplot comparativo:

- 3 features en el eje Y
- 2 clases en el eje X
- Medianas, cuartiles y outliers visibles
- Diferencias estadísticas evidentes

8.3 Identificación de Features Importantes

Métodos simples:

1. **Varianza entre clases:** Features con alta varianza entre clases son discriminativas

2. **ANOVA F-test:** Test estadístico de diferencias entre grupos
3. **Mutual Information:** Cuánta información comparte una feature con la clase

Ranking de importancia:

Feature	Importancia
spectral_centroid	0.85
mfcc_1	0.78
zcr	0.72
rms	0.65
spectral_rolloff	0.58

ACTIVIDADES INTERACTIVAS (OPTATIVAS)

Actividad 1: Interpretación de Espectro

Escenario: Observas un espectro FFT con picos en:

- 220 Hz (magnitud alta)
- 440 Hz (magnitud media)
- 880 Hz (magnitud baja)

Preguntas:

1. ¿Cuál es la frecuencia fundamental?
2. ¿Qué relación hay entre los picos?
3. ¿Qué tipo de sonido esperas escuchar?

Respuesta guía:

1. Fundamental: 220 Hz (La3, la más baja y fuerte)
2. Relación: Armónicos ($440 = 2 \times 220$, $880 = 4 \times 220$)
3. Sonido: Nota musical con timbre rico (múltiples armónicos)

Actividad 2: Elección de Parámetros STFT

Desafío: Debes analizar:

- **Caso A:** Canto de pájaro (muy rápido, frecuencias altas)
- **Caso B:** Nota de órgano sostenida (lento, frecuencias bajas)

Propón parámetros n_fft y hop_length para cada caso.

Respuesta guía:

Caso A (pájaro rápido):

- n_fft : 1024 (ventana corta para buena resolución temporal)
- hop_length : 256 (mucho superposición para capturar cambios rápidos)

Caso B (órgano lento):

- n_fft : 4096 (ventana larga para buena resolución frecuencial)
- hop_length : 1024 (menos superposición, la señal cambia poco)

Actividad 3: Análisis de Correlación

Observa la matriz de correlación:

- rms_energy y spectral_energy: 0.92
- zcr y spectral_centroid: -0.15
- mfcc_1 y mfcc_2: 0.08

Preguntas:

1. ¿Qué features podrías eliminar por redundancia?
2. ¿Qué pares de features aportan información independiente?
3. ¿Por qué ZCR y centroid tienen correlación negativa débil?

Respuesta guía:

1. Eliminar: spectral_energy (redundante con rms_energy, $r=0.92$)
2. Independientes: mfcc_1 vs mfcc_2 ($r=0.08$), zcr vs centroid ($r=-0.15$)
3. ZCR alto $\rightarrow$ señal "áspera" $\rightarrow$ más energía en altas frecuencias $\rightarrow$ centroid alto. Pero la relación no es lineal ni fuerte.

RESUMEN DE CONCEPTOS CLAVE

Concepto	Propósito	Herramienta	Insight clave
FFT	Descomponer en frecuencias	<code>np.fft.fft()</code>	Separa tonos mezclados
STFT	Análisis tiempo-frecuencia	<code>librosa.stft()</code>	Ventanas deslizantes
Espectrograma	Visualizar evolución espectral	<code>librosa.display.specshow()</code>	Patrones temporales
Features espectrales	Caracterizar timbre	<code>librosa.feature.*</code>	Centroid, rolloff, bandwidth
Correlación	Detectar redundancia	<code>np.corrcoef()</code>	Eliminar features duplicadas
PCA	Visualizar multidimensionalidad	<code>sklearn.decomposition.PCA</code>	Proyección 2D/3D
Outliers	Detectar anomalías	IQR, 3-sigma	Limpieza de datos

EVALUACIÓN FORMATIVA (OPTATIVAS)

Preguntas de Verificación:

1. Nivel Básico:

- ¿Qué información te da la FFT que el waveform no muestra?
- Explica con tus palabras qué es un espectrograma.
- ¿Por qué usamos ventanas en la STFT?

2. Nivel Intermedio:

- Si aumentas n_fft de 2048 a 4096, ¿qué mejora y qué empeora?
- Dos features tienen correlación de 0.95. ¿Qué harías y por qué?
- Interpreta: un audio tiene centroid en 3000 Hz vs otro en 500 Hz.

3. Nivel Avanzado:

- Diseña un pipeline de EDA para un dataset de 1000 audios con 5 clases.
- Explica por qué la FFT produce valores complejos y qué significa la magnitud.
- Propón un método para detectar automáticamente si un audio está corrupto o es ruido puro.

RECURSOS ADICIONALES

Documentación y Tutoriales:

- [Librosa: Spectral Features](#)
- [SciPy FFT Tutorial](#)
- [Understanding FFT - Better Explained](#)

Libros y Cursos:

-  [Speech and Language Processing - Jurafsky](#) - Capítulo sobre procesamiento de señal
-  [Coursera: Audio Signal Processing](#)
-  [NLTK Book](#) - Sección de features

Repositorios GitHub:

-  [NVIDIA DeepLearningExamples](#) - Ejemplos de ASR
-  [HuggingFace Transformers](#) - Modelos pre-entrenados
-  [500 AI Projects](#) - Proyectos con código

Herramientas Interactivas:

- **FFT Visualizer:** [Javier Montenegro](#)
- **Spectrogram Viewer:** Online tools para subir audio y ver espectrograma
- **Audacity:** Software libre para análisis visual manual

GLOSARIO

Término	Definición
EDA	Exploratory Data Analysis: análisis exploratorio de datos
FFT	Fast Fourier Transform: algoritmo eficiente de Fourier
STFT	Short-Time Fourier Transform: FFT en ventanas deslizantes
Espectro	Distribución de energía por frecuencias
Espectrograma	Representación visual tiempo-frecuencia
Formante	Picos de energía en espectro vocal (resonancias)
Armónico	Múltiplo entero de la frecuencia fundamental
Feature	Característica extraída para análisis/modelado
Outlier	Valor atípico o anómalo
Correlación	Medida de relación lineal entre variables
PCA	Principal Component Analysis: reducción dimensional
Ventana (window)	Función de suavizado para STFT
Hop length	Desplazamiento entre ventanas consecutivas

PRÓXIMOS PASOS

Con el EDA completado, avanzamos al **EJE II: Extracción de Características y Modelado Predictivo**:

- **MFCCs**: Coeficientes cepstrales avanzados para reconocimiento de voz
- **Ingeniería de features**: Creación de características personalizadas
- **Preparación para ML**: Estructuración de datasets para scikit-learn

Checklist de salida del Tema 3:

- ☐ Entiendo el propósito del EDA en audio
- ☐ Puedo aplicar e interpretar la FFT
- ☐ Sé generar y leer espectrogramas
- ☐ Extraigo features espectrales con librosa
- ☐ Detecto correlaciones y outliers
- ☐ Visualizo datos para identificar patrones

¿Preguntas? Recuerda: *El EDA no es un trámite, es tu mapa del tesoro*. Las insights que descubras aquí guiarán todo tu trabajo posterior de modelado.

Material desarrollado para: Procesamiento Digital de Señales de Audio

Nivel: Intermedio

Duración estimada: 4-5 horas de estudio + práctica