




TECNICATURA SUPERIOR EN

Ciencia de Datos e Inteligencia Artificial

Aprendizaje automático

Módulo 1




Docente
Cra. Sol Figueroa

Diplomatura en Nuevas Tecnologías

Especialista en Deep Learning & Machine Learning

Especialista en Business Intelligence

Técnica Superior en Ciencia de Datos e IA



Programa de la Materia

Módulo 1


Introducción al Aprendizaje Automático

- Definición de aprendizaje automático.
- Tipos de aprendizaje: supervisado, no supervisado, por refuerzo.
- Ciclo de vida de un proyecto de ML.
- Introducción a herramientas y bibliotecas (Scikit-Learn).

Módulo 2

Aprendizaje Supervisado y No Supervisado

- Aprendizaje supervisado: regresión y clasificación.
- Principales algoritmos: Regresión Lineal, Regresión Logística, Árboles de Decisión, SVM.
- Aprendizaje no supervisado: clustering y reducción de dimensionalidad.
- Algoritmos clave: K-means- DBscan
- Casos de uso y aplicaciones.



Programa de la Materia

Módulo 3


Métricas de Evaluación de Modelos

- Métricas para clasificación: Precisión, Recall, F1-score, Matriz de confusión.
- Métricas para regresión: RMSE, MAE, R^2 .
- Evaluación de clustering: Coeficiente de Silhouette, Elbow.
- Validación cruzada y particionamiento de datos.
- Sesgo y varianza: overfitting y underfitting.

Módulo 4


Ajuste y Optimización de Modelos

- Ajuste de hiperparámetros: Grid Search, Random Search.
- Regularización: L1, L2 y Elastic Net.
- Selección de características (Feature Selection y Feature Engineering).
- Explicabilidad de modelos: SHAP.
- Implementación en producción: consideraciones y herramientas.



01

Introducción al aprendizaje automático



Introducción

Bienvenidos al módulo de Aprendizaje Automático

El aprendizaje automático no es solo una herramienta tecnológica; es un paradigma que permite a las máquinas *aprender de los datos*, identificar patrones y tomar decisiones con mínima intervención humana.

Desde sistemas de recomendación hasta diagnósticos médicos, pasando por vehículos autónomos y chatbots inteligentes, Machine Learning está redefiniendo industrias y solucionando problemas complejos.

En este módulo, abordaremos:


- **Los pilares teóricos:** algoritmos supervisados y no supervisados
- **La práctica con impacto:** cómo preprocesar datos, entrenar modelos y evaluar su desempeño.
- **Los desafíos éticos:** sesgos, interpretabilidad y responsabilidad en el desarrollo de IA.




Introducción

¿Listos para embarcarse en este viaje?

Comenzaremos con una pregunta esencial



¿Cómo pueden los datos convertirse en conocimiento automático?





¿Qué es el Aprendizaje Automático?

El aprendizaje automático es una rama de la inteligencia artificial (IA) que se centra en desarrollar algoritmos capaces de aprender patrones a partir de datos y tomar decisiones o realizar predicciones sin ser programados explícitamente para ello.

En lugar de escribir reglas específicas para cada tarea, los modelos de aprendizaje automático aprenden directamente de los ejemplos proporcionados.

Piensen en cómo aprendemos a diferenciar entre perros y gatos. No necesitamos que alguien nos explique cada característica; simplemente observamos varios ejemplos y desarrollamos un "modelo mental" para identificar cada animal. El aprendizaje automático funciona de manera similar, pero con datos y algoritmos.




¿Qué es el Aprendizaje Automático?

¿Por qué es importante?

El aprendizaje automático tiene aplicaciones en prácticamente todos los campos:

- Medicina: Diagnóstico automatizado basado en imágenes médicas.
- Finanzas: Detección de fraudes y análisis predictivo.
- Marketing: Personalización de campañas publicitarias.
- Industria: Mantenimiento predictivo y optimización de procesos.

Además, su capacidad para manejar grandes volúmenes de datos lo convierte en una herramienta indispensable en la era digital.




Clasificación del Aprendizaje Automático

El aprendizaje automático se divide en tres categorías principales según el tipo de datos disponibles y la tarea que se desea realizar:

1. Aprendizaje Supervisado

En este enfoque, el modelo aprende a partir de **datos etiquetados**, es decir, ejemplos donde conocemos tanto las entradas como las salidas esperadas.

- Ejemplo: Predecir el precio de una casa basado en características como tamaño, ubicación y número de habitaciones.
- Subtareas comunes: Clasificación (etiquetar correos como spam o no spam) y regresión (predecir valores numéricos).



Clasificación del Aprendizaje Automático

2. Aprendizaje No Supervisado


Aquí trabajamos con **datos no etiquetados**, y el objetivo es descubrir patrones o estructuras ocultas en ellos.

- Ejemplo: Agrupar clientes según su comportamiento para crear campañas personalizadas.
- Subtareas comunes: Clustering (agrupamiento) y reducción de dimensionalidad (simplificar conjuntos de datos).

3. Aprendizaje por Refuerzo

Este enfoque se basa en entrenar un agente que interactúa con un entorno, tomando decisiones para maximizar una recompensa acumulada a lo largo del tiempo.


- Ejemplo: Entrenar un robot para navegar por una habitación evitando obstáculos.
- Aplicaciones comunes: Juegos (como AlphaGo), control robótico y sistemas autónomos.




Conceptos Clave

Antes de avanzar más profundamente en futuros temas, hay algunos términos fundamentales que debemos conocer:

1. **Datos:** El combustible del aprendizaje automático; pueden ser imágenes, texto, números, etc.
2. **Modelo:** La representación matemática del problema que queremos resolver.
3. **Entrenamiento:** El proceso mediante el cual el modelo aprende patrones a partir de los datos.
4. **Evaluación:** Medir qué tan bien funciona el modelo con datos nuevos o no vistos previamente.




Conceptos para debatir



¿Qué aplicaciones del aprendizaje automático conocen o han utilizado sin darse cuenta?

¿Cómo creen que estas tecnologías impactan nuestras vidas diarias?




Vamos a profundizar en la definición de aprendizaje automático, un concepto clave que nos permitirá entender mejor su alcance y su funcionamiento.

¿Qué es el Aprendizaje Automático?


El aprendizaje automático (*Machine Learning*, en inglés) es un campo de la inteligencia artificial que se enfoca en el desarrollo de algoritmos y modelos estadísticos que permiten a las computadoras aprender a partir de datos y mejorar su desempeño en una tarea específica sin ser explícitamente programados.

En otras palabras, en lugar de escribir reglas detalladas para resolver un problema, el aprendizaje automático permite que los sistemas aprendan patrones directamente de los datos y generalicen ese conocimiento para realizar predicciones o tomar decisiones en situaciones nuevas.



Elementos Clave de la Definición


1. **Aprender a partir de datos**
El aprendizaje automático se basa en el análisis de datos históricos o ejemplos para identificar patrones y relaciones. Estos datos pueden ser estructurados (como tablas de Excel) o no estructurados (como imágenes o texto).
2. **Sin ser explícitamente programados**
A diferencia de los enfoques tradicionales de programación, donde el desarrollador define cada paso que debe seguir el sistema, en el aprendizaje automático el modelo descubre las reglas por sí mismo.
3. **Mejorar el desempeño**
El objetivo es que el modelo se vuelva más preciso y eficiente a medida que se expone a más datos o se ajusta su configuración.
4. **Tarea específica**
Los modelos de aprendizaje automático están diseñados para resolver problemas concretos, como clasificar imágenes, predecir precios o recomendar productos.



Ejemplo Práctico


Imaginemos que queremos crear un sistema para identificar si un correo electrónico es spam o no spam. En lugar de escribir manualmente reglas como "si el correo contiene la palabra 'oferta', entonces es spam", podemos entrenar un modelo de aprendizaje automático con miles de ejemplos de correos etiquetados como spam o no spam.

El modelo aprenderá automáticamente las características asociadas con el spam y podrá clasificar nuevos correos con precisión.





Diferencia entre Aprendizaje Automático y Programación Tradicional

Programación Tradicional	Aprendizaje Automático
El programador define las reglas explícitamente.	El algoritmo aprende las reglas a partir de los datos.
Funciona bien para problemas con reglas claras y predecibles.	Es ideal para problemas complejos donde las reglas no son obvias.
Requiere actualización manual si cambian las condiciones.	Se adapta automáticamente a nuevos datos.



"El aprendizaje automático no trata de enseñar a las máquinas a pensar como humanos, sino de enseñarles a aprender como humanos."

El aprendizaje automático es una herramienta poderosa que nos permite resolver problemas complejos de manera eficiente y escalable.




Aprendizaje Supervisado

El aprendizaje supervisado se basa en **datos etiquetados**, donde cada ejemplo incluye variables de **entrada (features)** y una **salida conocida (etiqueta)**.

El objetivo es entrenar un modelo que aprenda la relación entre las entradas y las salidas para predecir resultados en nuevos datos.

Subtareas principales:

1. **Clasificación:** Asignar etiquetas discretas (ejemplo: "spam" vs. "no spam")
2. **Regresión:** Predecir valores numéricos continuos (ejemplo: precio de una vivienda).




Terminology

Features / Factors / Predictors / X Variables /
Independent Variables / Attributes / Dimensions

Targets /
Labels /
Annotations /
Response /
Y Variable /
Dependent Variable

Observations /
Instances /
Examples /
Feature Vectors

	Neighbor- hood	School district	Square footage	Number of bedrooms	Year built	Market sale price
House 1	Weycroft	Wake	3400	4	2010	\$612,000
House 2	Horton Creek	Wake	4200	5	2008	\$675,000
House 3	Cary Park	Chatham	3250	4	2012	\$520,000
...	...	...	...	...	...	...



Ejemplos Detallados

1. Detección de spam:


- Entradas: Asunto del correo, remitente, presencia de enlaces.
- Salida: Etiqueta "spam" o "no spam".
- Algoritmos comunes: Árboles de decisión, Naïve Bayes, SVM.

2. Predicción de precios de viviendas:

- Entradas: Metros cuadrados, ubicación, número de habitaciones.
- Salida: Valor numérico (precio).
- Algoritmos comunes: Regresión lineal, Random Forest.


3. Diagnóstico médico:

- Entradas: Resultados de pruebas, síntomas, historial clínico
- Salida: Diagnóstico (ejemplo: "enfermedad presente" o "ausente")



Algoritmos clave:

- **Clasificación:** Regresión logística (a pesar de su nombre, se usa para clasificación), SVM, Redes Neuronales.
- **Regresión:** Regresión lineal, Gradient Boosting.



Aprendizaje No Supervisado

En este enfoque, **los datos no están etiquetados**, y el objetivo es descubrir patrones ocultos o estructuras intrínsecas.

No hay una "respuesta correcta" predefinida.

Subtareas principales:

1. **Clustering:** Agrupar datos similares (ejemplo: segmentación de clientes).
2. **Reducción de dimensionalidad:** Simplificar datos complejos para visualización o análisis (ejemplo: PCA).


Ejemplo

Segmentación de clientes:

- Entradas: Historial de compras, frecuencia de uso, preferencias.
- Salida: Grupos como "clientes leales" o "ocasionales"..
- Algoritmos comunes: K-Means, DBSCAN.

Algoritmos clave:

- K-Means, PCA, Clustering Jerárquico.



Aprendizaje por Refuerzo

Un agente aprende a tomar decisiones mediante interacción con un entorno, recibiendo recompensas o penalizaciones. El objetivo es maximizar la recompensa acumulada a largo plazo.

Componentes clave:


- Agente: Entidad que toma decisiones (ejemplo: robot).
- Entorno: Contexto donde actúa el agente (ejemplo: videojuego).
- Política: Estrategia que define las acciones del agente.

Ejemplos Detallados

1. Entrenamiento de robots en videojuegos:
 - Acciones: Moverse, saltar, disparar..
 - Recompensas: Puntos por alcanzar objetivos..
 - Algoritmos comunes: Q-Learning, Deep Q-Networks (DQN).
2. Vehículos autónomos:
 - Entorno: Carreteras, semáforos, peatones.
 - Recompensas: Llegar al destino de forma segura y eficiente.
 - Algoritmos comunes: Policy Gradient, Actor-Critic.


Algoritmos clave:

- Q-Learning, DQN, A3C (Asynchronous Advantage Actor-Critic).



Comparación de los Tipos de Aprendizaje

Criterio	Supervisado	No Supervisado	Por Refuerzo
Datos	Etiquetados	No etiquetados	Interacción con entorno
Objetivo	Predecir salidas conocidas	Descubrir patrones ocultos	Maximizar recompensas
Aplicaciones	Spam detection, diagnóstico	Segmentación de clientes	Robótica, juegos
Algoritmos comunes	SVM, Regresión Lineal	K-Means, PCA	Q-Learning, DQN




Consideraciones Clave

- **Supervisado:** Requiere datos etiquetados de calidad. Es vulnerable al *sobreajuste* si el modelo memoriza los datos en lugar de generalizar.
- **No Supervisado:** Útil para exploración de datos, pero los resultados pueden ser difíciles de interpretar sin contexto.
- **Por Refuerzo:** Costoso en tiempo y recursos, pero ideal para entornos dinámicos y complejos.

Casos de Confusión Comunes

- **Regresión Logística:** Aunque incluye "regresión" en su nombre, se usa para clasificación binaria (ejemplo: predecir si un cliente abandonará un servicio).
- **SVM:** Funciona tanto para clasificación como para regresión, dependiendo de su configuración.

Con estos fundamentos, podrán identificar qué tipo de aprendizaje aplicar según la naturaleza de sus datos y objetivos.





Ejemplos de Implementación de Aprendizaje Automático

El aprendizaje automático se aplica en una amplia variedad de sectores, desde la salud hasta el comercio electrónico.



Predecir Gastos Médicos

- **Objetivo:** Estimar los gastos médicos basados en atributos del cliente, como edad, índice de masa corporal (IMC) y hábitos de salud.
- **Técnica:** Aprendizaje supervisado (regresión).
- **Implementación:** Se utiliza un modelo de regresión lineal o Random Forest para predecir los costos basados en datos históricos.
- **Aplicación:** Mejora la precisión en la fijación de precios de seguros y ayuda a gestionar riesgos financieros en empresas aseguradoras



2. Reconocimiento Facial


- Objetivo: Identificar a una persona en imágenes o videos.
- Técnica: Aprendizaje supervisado (clasificación).
- Implementación: Se entrenan redes neuronales convolucionales (CNN) con un conjunto de imágenes etiquetadas para distinguir entre individuos.
- Aplicación: Usado en sistemas de seguridad, autenticación biométrica y redes sociales



3. Detección de Cáncer de Mama

- Objetivo: Predecir si un tumor es maligno o benigno.
- Técnica: Aprendizaje supervisado (clasificación).
- Implementación: Se utiliza un clasificador como SVM o Random Forest con datos de características del tumor (textura, perímetro, área).
- Aplicación: Ayuda en el diagnóstico temprano y mejora la precisión en la detección de enfermedades.

[BBC](#)




Ciclo de Vida de un Proyecto de Machine Learning

El ciclo de vida de un proyecto de *machine learning* (ML) es un proceso estructurado y iterativo que abarca desde la definición del problema hasta el mantenimiento continuo del modelo en producción.

Su objetivo es garantizar que los modelos sean eficientes, escalables y alineados con las necesidades del negocio.

A continuación, se detallan las fases clave, basadas en metodologías como CRISP-ML(Q) y enfoques industriales..



Ciclo de Vida de un Proyecto de Machine Learning




1. Planificación y Definición del Problema

Esta fase establece las bases del proyecto y es crítica para su éxito:

- Identificación del objetivo: Determinar qué problema se resolverá (ejemplo: predecir ventas, clasificar imágenes).
- KPIs y métricas de éxito: Definir cómo se medirá el desempeño del modelo (ejemplo: precisión, AUC-ROC, error cuadrático medio).
- Requisitos técnicos y éticos: Evaluar limitaciones de recursos, privacidad de datos y sesgos potenciales.

Ejemplo : Si el objetivo es reducir la tasa de abandono de clientes, se define si se usará clasificación binaria (*churn* vs. *no churn*) y qué datos son relevantes (historial de compras, interacciones con soporte).



Ciclo de Vida de un Proyecto de Machine Learning

2. Recolección y Preparación de Datos

Recolección

- Identificar fuentes de datos (bases de datos internas, APIs, sensores IoT)..
- Garantizar la calidad: Evitar datos incompletos, duplicados o sesgados

Preprocesamiento

- Limpieza: Manejar valores nulos, outliers y errores de formato.
- Transformación: Normalización, codificación de variables categóricas (ejemplo: *one-hot encoding*).
- División de datos: Separar en conjuntos de entrenamiento (*train*), validación y prueba (*test*) antes de cualquier manipulación para evitar *data leakage*.




Ciclo de Vida de un Proyecto de Machine Learning

3. Análisis Exploratorio de Datos (EDA)

- **Visualización:** Gráficos de distribución, correlaciones y tendencias.
- **Estadística descriptiva:** Media, desviación estándar, percentiles.
- **Feature engineering:** Crear nuevas variables (ejemplo: calcular el ratio de uso mensual de un servicio)

Herramientas: Python (Pandas, Matplotlib), R (ggplot2).



Ciclo de Vida de un Proyecto de Machine Learning

4. Construcción y Entrenamiento del Modelo


Selección de algoritmos

- **Supervisado:** Regresión lineal, Random Forest, Redes Neuronales.
- **No supervisado:** K-Means, PCA.
- **Refuerzo:** Q-Learning.

Entrenamiento

- Ajustar hiperparámetros mediante técnicas como *grid search* o *random search*.
- Usar validación cruzada (*cross-validation*) para evitar sobreajuste (*overfitting*).

Ejemplo: En un modelo de detección de fraudes, se prueba con SVM y Random Forest para comparar precisión y recall.



5. Evaluación del Modelo

- **Métricas cuantitativas:**


- **Clasificación:** Precisión, recall, F1-score.



- **Regresión:** RMSE, MAE.

- **Métricas cualitativas:** Interpretabilidad del modelo (ejemplo: SHAP values)


Caso de error: Si el modelo tiene alta precisión en *train* pero bajo desempeño en *test*, podría deberse a *overfitting*. Soluciones: Regularización (L1/L2) o aumento de datos.



6. Despliegue en Producción

- **Integración:** Implementar el modelo en APIs, aplicaciones móviles o sistemas embebidos.
- **Escalabilidad:** Usar herramientas como Docker o Kubernetes para manejar cargas variables..
- **Monitoreo inicial:** Validar que el modelo funcione con datos reales (ejemplo: latencia, tasa de errores)

Ejemplo: Un modelo de recomendación de productos se integra en la página web de un e-commerce usando AWS SageMaker.




7. Monitoreo y Mantenimiento Continuo

- **Drift detection:** Identificar cambios en la distribución de los datos (ejemplo: tendencias estacionales).
- **Reentrenamiento:** Actualizar el modelo con nuevos datos periódicamente.
- **Retroalimentación:** Incorporar *feedback* de usuarios para ajustar el sistema (ejemplo: correcciones en etiquetas).

Ejemplo:

Un modelo de predicción de demanda en retail debe reentrenarse mensualmente para reflejar cambios en hábitos de compra.





8. Documentación y Gobernanza

- **Reproducibilidad:** Registrar versiones de datos, código y modelos (ejemplo: MLflow)
- **Ética:** Auditar sesgos en predicciones (ejemplo: equidad en préstamos bancarios).

Enfoque Iterativo

El ciclo de vida no es lineal. Por ejemplo:


1. Si el modelo tiene bajo rendimiento, se retrocede a la fase de *feature engineering*.
2. Si se detecta *data drift*, se revisa la recolección de datos.



El ciclo de vida de un proyecto de ML combina rigor técnico y adaptabilidad.

Desde la definición del problema hasta el monitoreo en producción, cada fase requiere atención a detalles como la calidad de los datos, la elección de algoritmos y la ética en las decisiones automatizadas.

Siguiendo metodologías como CRISP-ML(Q), los equipos pueden crear soluciones robustas y alineadas con las necesidades empresariales.



¡Muchas gracias!