

TECNICATURA SUPERIOR EN

Ciencia de Datos e IA


Desarrollo de Sistemas de IA

Capítulo 2

01

Capítulo 2

Bibliotecas a utilizar



Bibliotecas para Machine Learning

Scikit Learn

scikit-learn

Machine Learning en Python

Comenzando

Puntos destacados de lanzamiento para 1.3

GitHub


- Herramientas simples y eficientes para el análisis predictivo de datos.
- Accesible para todos y reutilizable en varios contextos.
- Construido sobre NumPy, SciPy y matplotlib
- Código abierto, comercialmente utilizable - licencia BSD

Clasificación

Identificar a qué categoría pertenece un objeto.

Aplicaciones: Detección de spam, reconocimiento de imagen.

Algoritmos: Impulsor de gradiente, vecinos más cercanos, bosque aleatorio, regresión logística, y más...




Regresión

Predicir un atributo de valor continuo asociado con un objeto.

Aplicaciones: Respuesta a medicamentos, precios de las acciones.

Algoritmos: Impulsor de gradiente, vecinos más cercanos, bosque aleatorio, cresta, y más...




Agrupamiento

Agrupación automática de objetos similares en conjuntos.

Aplicaciones: Segmentación de clientes, Agrupando resultados experimentales

Algoritmos: k-medios, HDBSCAN, jerárquico agrupamiento, y más...



Bibliotecas para Machine Learning

Scikit Learn

Scikit-learn es una librería de aprendizaje automático en Python que proporciona una variedad de herramientas y algoritmos para realizar tareas relacionadas con el análisis y la construcción de modelos de datos.

Las principales funciones de scikit-learn incluyen:

Preparación de Datos: Scikit-learn ofrece herramientas para la limpieza, transformación y preparación de datos antes de usarlos para entrenar modelos de aprendizaje automático.

Algoritmos de Aprendizaje Automático: La librería incluye una amplia gama de algoritmos para tareas como clasificación, regresión, agrupación, reducción de dimensionalidad y más. Esto permite a los usuarios seleccionar el algoritmo más adecuado para su problema específico.



Bibliotecas para Machine Learning


Scikit Learn

Validación de Modelos: Proporciona funciones para evaluar y validar modelos, como división de datos en conjuntos de entrenamiento y prueba, validación cruzada y métricas de rendimiento.

Tuning de Hiperparámetros: Ayuda en la optimización de los hiperparámetros de los modelos para mejorar su rendimiento.

Selección de Características: Ofrece métodos para seleccionar las características más relevantes y reducir la dimensionalidad de los datos.

<https://scikit-learn.org/stable/index.html>




Bibliotecas para Machine Learning

Scikit Learn


```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
model = LogisticRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
accuracy = accuracy_score(y_test, y_pred)
```



Bibliotecas para Machine Learning

Numpy




Bibliotecas para Machine Learning

Numpy

Su nombre proviene de "Numerical Python" y su función principal es proporcionar estructuras de datos y funciones para realizar operaciones numéricas eficientes en matrices y arreglos multidimensionales.

Algunas funciones a destacar:

Manipulación Eficiente de Datos: NumPy ofrece un tipo de dato llamado "array" (arreglo) que es eficiente en términos de espacio y tiempo. Estos arreglos permiten almacenar y manipular grandes conjuntos de datos numéricos, como características y etiquetas en el aprendizaje automático.



Bibliotecas para Machine Learning


Numpy

Cálculos Numéricos Rápidos: Las operaciones en arreglos NumPy son altamente optimizadas y se ejecutan más rápido que las operaciones similares en listas de Python. Esto es esencial cuando se manejan cálculos complejos en matrices de datos, como multiplicaciones de matrices y otras operaciones lineales de álgebra.

Integración con Librerías de Aprendizaje Automático: Muchas librerías de aprendizaje automático, como scikit-learn y TensorFlow, utilizan arreglos NumPy como formato de entrada para entrenar modelos y realizar operaciones matemáticas.

Operaciones Matemáticas y Estadísticas: NumPy proporciona una amplia gama de funciones matemáticas y estadísticas que son esenciales para el procesamiento y análisis de datos en el aprendizaje automático.

<https://numpy.org/>




Bibliotecas para Machine Learning

NLTK



Natural Language Analysis
with Python NLTK



Bibliotecas para Machine Learning

NLTK

NLTK (Natural Language Toolkit) es una librería en Python que se utiliza para trabajar con procesamiento de lenguaje natural (NLP, por sus siglas en inglés). Su objetivo principal es proporcionar herramientas y recursos para analizar, procesar y comprender el lenguaje humano de manera computacional.

Características

Procesamiento de Texto: NLTK ofrece una amplia gama de funciones para preprocesar y manipular texto, como tokenización (división del texto en palabras o frases), segmentación de oraciones y eliminación de caracteres no deseados.




Bibliotecas para Machine Learning

NLTK

Análisis de Sentimiento: NLTK permite analizar el sentimiento en textos, lo que es útil para determinar si un texto tiene una connotación positiva, negativa o neutral.

Extracción de Información: Puede utilizarse para extraer información específica de un texto, como nombres de personas, ubicaciones, fechas, etc.

Análisis Gramatical: NLTK permite analizar la estructura gramatical de las oraciones, lo que es útil para comprender la relación entre las palabras en un contexto




Bibliotecas para Machine Learning

NLTK

```
import nltk
from nltk.tokenize import word_tokenize
from nltk.sentiment import SentimentIntensityAnalyzer


nltk.download('punkt')
nltk.download('vader_lexicon')

text = "Python is amazing for NLP!"
tokens = word_tokenize(text)
sia = SentimentIntensityAnalyzer()
sentiment = sia.polarity_scores(text)
```



Bibliotecas para Machine Learning

Stats Models



Bibliotecas para Machine Learning

Stats Models

La biblioteca Statsmodels es una herramienta en Python utilizada para ajustar y analizar modelos estadísticos.

Proporciona una amplia gama de métodos y funcionalidades para realizar análisis de datos, estimación de parámetros, pruebas de hipótesis y construcción de modelos estadísticos.

Esta biblioteca es especialmente útil en el ámbito de la econometría, estadística y análisis de datos.



Bibliotecas para Machine Learning


Stats Models

Algunas características y usos de la biblioteca "statsmodels" incluyen:

Regresión y Modelos Lineales: Puedes ajustar modelos de regresión lineal y lineal múltiple, así como explorar la relación entre variables mediante análisis de residuos y pruebas de significancia.

Modelos de Series Temporales: La biblioteca permite el análisis de series temporales y la construcción de modelos ARIMA (AutoRegressive Integrated Moving Average) para el pronóstico.

Análisis de Varianza (ANOVA): Puedes realizar análisis de varianza y pruebas de efectos fijos o aleatorios para comparar diferentes grupos.



Bibliotecas para Machine Learning

Stats Models

Modelos de Regresión Logística: Puedes ajustar modelos de regresión logística para problemas de clasificación.


Análisis de Componentes Principales (PCA): La biblioteca ofrece funcionalidades para realizar PCA y analizar la varianza explicada por componentes principales.

Pruebas de Hipótesis: Puedes realizar diversas pruebas estadísticas para evaluar la significancia de los parámetros estimados en tus modelos.



Bibliotecas para Deep Learning

Keras




Bibliotecas para Deep Learning

Keras

Keras es una interfaz de programación de aplicaciones (API) de código abierto diseñada para facilitar y acelerar el desarrollo de modelos de aprendizaje profundo, también conocido como deep learning.

Esta API está escrita en Python y permite a los desarrolladores crear, entrenar y evaluar redes neuronales de manera eficiente y flexible.




Bibliotecas para Deep Learning

Keras

Construcción de Redes Neuronales: Keras proporciona una forma sencilla y modular de definir la arquitectura de las redes neuronales. Los desarrolladores pueden crear capas neuronales, conectarlas y configurar sus propiedades con facilidad.

Entrenamiento de Modelos: Keras simplifica el proceso de entrenamiento de modelos de aprendizaje profundo. Proporciona métodos para compilar modelos con funciones de pérdida, optimizadores y métricas de evaluación. El proceso de retropropagación y actualización de pesos se maneja automáticamente.

Flexibilidad: Keras es flexible en términos de arquitectura y tipos de modelos. Puedes crear modelos secuenciales (capa por capa) o modelos más complejos con múltiples entradas y salidas.




Bibliotecas para Deep Learning

Keras

```
import tensorflow as tf
import keras
from keras import layers
```

```
# Define Sequential model with 3 layers
model = keras.Sequential(
    [
        layers.Dense(2, activation="relu", name="layer1"),
        layers.Dense(3, activation="relu", name="layer2"),
        layers.Dense(4, name="layer3"),
    ]
)
# Call model on a test input
x = tf.ones((3, 3))
y = model(x)
```



Bibliotecas para Deep Learning


Keras

Reutilización de Modelos Preentrenados: Keras permite cargar modelos preentrenados y adaptarlos a tareas específicas, lo que se conoce como transferencia de aprendizaje.

Visualización de Modelos: La API incluye herramientas para visualizar gráficamente la estructura y los detalles de tus modelos, lo que puede ser útil para comprender su complejidad.


A partir de TensorFlow 2.0, Keras se ha integrado como una parte integral de TensorFlow, lo que fortalece su posición como una API principal para construir modelos de aprendizaje profundo.

<https://keras.io/>



Bibliotecas para Deep Learning

Tensorflow




Bibliotecas para Deep Learning

Tensorflow

TensorFlow es una biblioteca de código abierto desarrollada por Google que se utiliza ampliamente en el ámbito del aprendizaje profundo (Deep Learning).

Está diseñada para facilitar la creación, entrenamiento y despliegue de modelos de redes neuronales y otras técnicas de aprendizaje automático.

TensorFlow se basa en el concepto de "tensores", que son matrices multidimensionales que representan datos y operaciones matemáticas.



Bibliotecas para Deep Learning


Tensorflow

Se usa principalmente para :

Construcción de Modelos: La biblioteca permite definir la arquitectura de modelos de redes neuronales de manera flexible y modular. Puedes crear capas, conectarlas y personalizar su estructura de acuerdo con tus necesidades.

Entrenamiento de Modelos: TensorFlow ofrece optimizadores y funciones de pérdida que facilitan el entrenamiento de modelos. La biblioteca automatiza la retropropagación de gradientes y el ajuste de pesos para minimizar la pérdida.

.



Bibliotecas para Deep Learning


Tensorflow

Despliegue de Modelos: Después de entrenar un modelo, TensorFlow proporciona herramientas para exportarlo y desplegarlo en diferentes entornos, como aplicaciones móviles, servidores web y sistemas embebidos.

Transferencia de Aprendizaje: TensorFlow facilita la reutilización de modelos preentrenados para tareas relacionadas, lo que acelera el proceso de entrenamiento y mejora el rendimiento en problemas con datos limitados.

GPU y TPU Acceleration: TensorFlow está optimizado para aprovechar hardware especializado como GPUs (unidades de procesamiento gráfico) y TPUs (unidades de procesamiento tensorial), lo que acelera significativamente el cálculo en modelos complejos.

<https://www.tensorflow.org/?hl=es-419>



Bibliotecas para Deep Learning Tensorflow

Implementa en cualquier lugar, a cualquier
escala



En la Web

TENSORFLOW.JS




En dispositivos móviles
y perimetrales

TENSORFLOW LITE



En servidores

TFX



Bibliotecas para Deep Learning

Tensorflow

Paso 1: Comprende de qué se trata el AA

TensorFlow 2.0 se diseñó con el objetivo de facilitar la creación de redes neuronales para el aprendizaje automático; por ello, TensorFlow 2.0 usa una API llamada Keras. El libro [Deep Learning with Python](#), por Francois Chollet, creador de Keras, es un excelente punto de partida. Lee los capítulos del 1 al 4 para comprender los conceptos fundamentales del AA desde la perspectiva de un programador. La segunda mitad del libro trata sobre áreas como la visión artificial, el procesamiento de lenguaje natural, el aprendizaje profundo generativo y mucho más. No te preocupes si estos temas son demasiado avanzados en esta instancia; los comprenderás a su debido tiempo.

AI and Machine Learning for Coders

A Programmer's Guide to Artificial Intelligence



AI and Machine Learning for Coders

por Laurence Moroney

Este libro introductorio ofrece un enfoque centrado en el código para aprender a implementar las situaciones de AA más comunes, como la visión artificial, el procesamiento de lenguaje natural (PLN) y el modelado de secuencia para entornos de ejecución incorporados, de la Web, de dispositivos móviles o de la nube.

[Ver libro](#) ↗

DEEP LEARNING with Python




Deep Learning with Python

por Francois Chollet


Este libro es una introducción práctica al aprendizaje profundo con Keras.

[Ver libro](#) ↗



Bibliotecas para Deep Learning

Pytorch




Bibliotecas para Deep Learning

Pytorch

PyTorch es una biblioteca de aprendizaje automático de código abierto que se utiliza ampliamente en el campo del aprendizaje profundo.

Fue desarrollada por el equipo de investigación de inteligencia artificial de Facebook y se destaca por su enfoque dinámico y flexible para construir y entrenar modelos de redes neuronales.

PyTorch es especialmente popular entre los investigadores y desarrolladores debido a su naturaleza intuitiva y su capacidad para expresar ideas de manera más cercana a cómo se piensan en el proceso de modelado.




Bibliotecas para Deep Learning

Pytorch

Construcción de Modelos: PyTorch permite definir la arquitectura de modelos de redes neuronales de manera más dinámica y expresiva. Los desarrolladores pueden utilizar la funcionalidad de programación imperativa, lo que hace que sea más fácil experimentar con diferentes ideas y ajustar los modelos sobre la marcha.

Entrenamiento de Modelos: La biblioteca ofrece optimizadores y funciones de pérdida para entrenar modelos de manera eficiente. El proceso de retropropagación y actualización de parámetros se realiza automáticamente.



Bibliotecas para Deep Learning


Pytorch

Procesamiento de Secuencias: PyTorch es popular en tareas de procesamiento de lenguaje natural (NLP) debido a su capacidad para trabajar con secuencias de manera eficiente.

Implementación de Modelos Avanzados: PyTorch es elegido a menudo para implementar modelos más avanzados y experimentales, como redes neuronales adversarias generativas (GANs) y modelos de atención.

Uso de GPUs: PyTorch es compatible con el uso de GPUs para acelerar el entrenamiento y la inferencia de modelos, lo que mejora el rendimiento.

<https://pytorch.org/>






Debate

¿Conocías estas bibliotecas?.

Describe al menos 3 de ellas.



¡Muchas gracias!